

第四章　分类



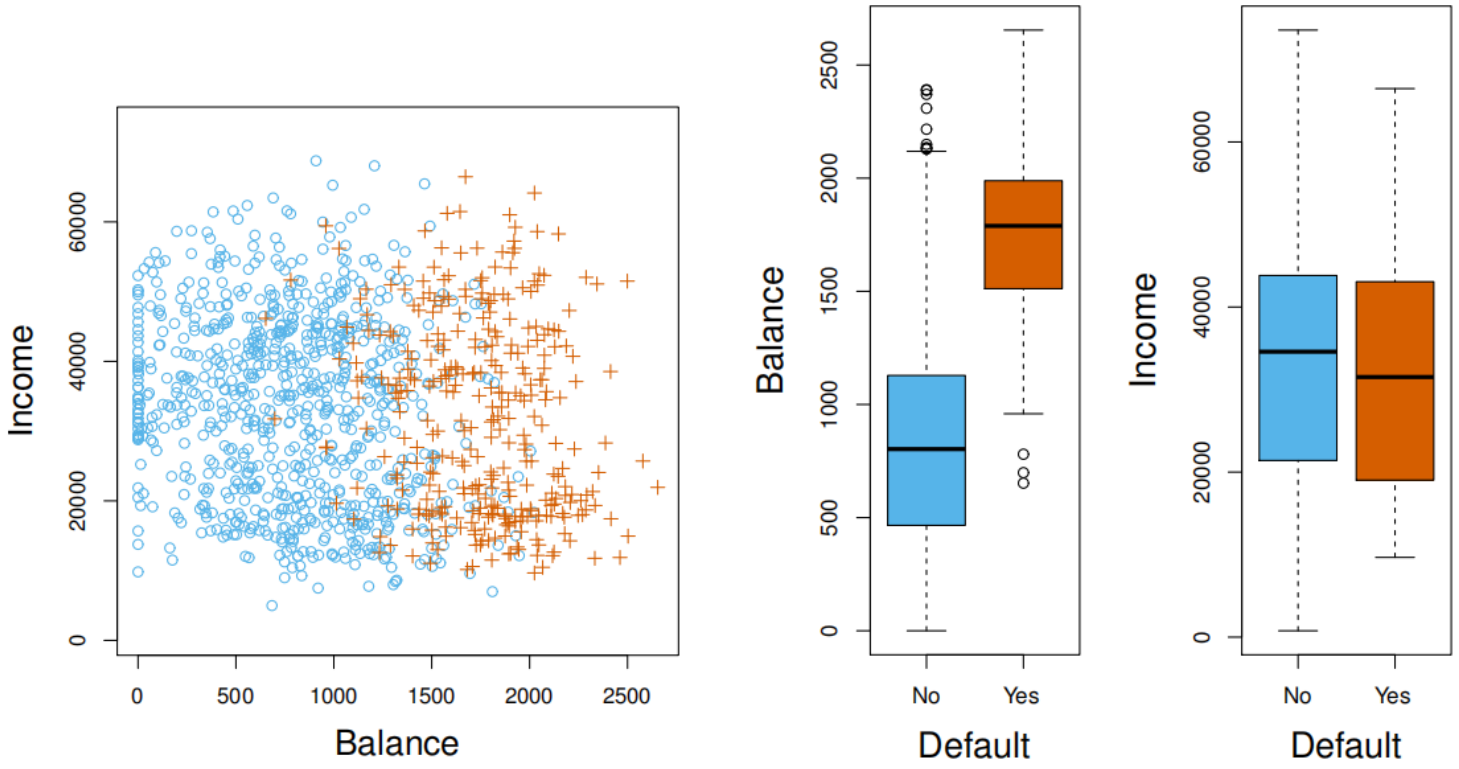
4.1. 分类问题概述

- 在很多情况下，响应变量是定性的(qualitative)，是**无序**集合$\mathcal{C}$中的值，例如
  - eye color $\in$ {borwn, blue, green}
  - email $\in$ {spam, ham}

- 给定一个特征向量X和一个定性的响应变量Y（Y的取值在集合$\mathcal{C}$中），分类任务是：以特征向量X为输入，建立函数$C(X)$，预测响应变量Y的取值；即，$C(X) \in \mathcal{C}$

- 通常，我们对X属于$\mathcal{C}$中每一类的**概率(probabilities)**更感兴趣
  - 例如，分析金融活动存在欺诈的**概率**，比只分析金融活动**是否存在**欺诈，更有价值

示例：Credit Card Default数据集



- Default数据集。左：部分个体的年收入与信用卡余额关系，信用卡贷款违约的标示为加号+，未违约的表示为圈o。中：default关于balance函数的箱线图。右：default关于income 函数的箱线图。

Default：违约；income：年收入；balance：月信用卡余额



4.2. 线性回归不可用

为什么线性回归不可用（两水平以上）

- **首先，分类任务的编码（123，abc）没有“数值大小”的概念。**
- 现在假设变量有三种可能取值的例子。假设现在要通过一个急诊室病人的症状来预测他的患病情况。

$$Y=\begin{cases}1, & \text{stroke（中风）}\\ 2, & \text{drug overdose（服药过量）}\\ 3, & \text{epileptic seizure（癫痫发作）}\end{cases}$$

- 这样的编码实际默认了一个有序的输出，把drug overdose放在stroke和epileptic seizure之间，表明stroke和drug overdose的差距与drug overdose和epileptic seizure的差距是一样的。
- 此时线性回归是不合适的，多类别**逻辑斯谛回归(Multiclass Logistic Regression)**或**判别分析(Discriminant Analysis)**则更合适

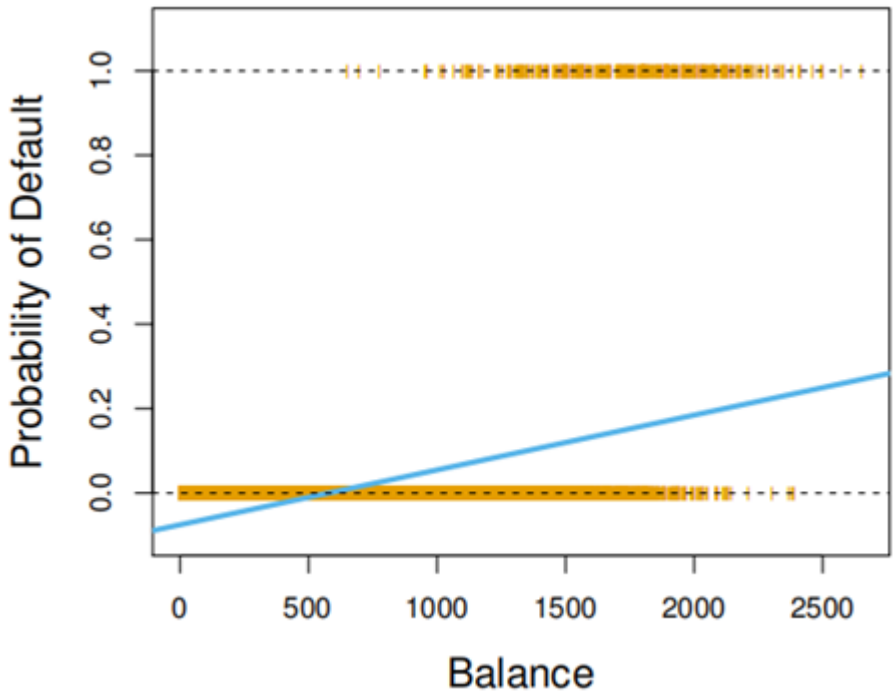
为什么线性回归不可用

- **即使是二分类，编码为01，并且视01为概率（属于1的概率），进行回归，也会产生不合理的结果。**
- 比如对Default数据集的分类任务，我们编码为：

$$Y = \begin{cases} 0, & \text{否（不违约）} \\ 1, & \text{是（违约）} \end{cases}$$

- 视其为概率，并建立合适的线性回归模型，如果$\hat{Y} > 0.5$，那么就预测为“是（违约）”
- 在二元的情况下，线性回归是可以使用的，它的结果和后续要讨论的线性辨别分析(linear discriminant analysis, LDA)的结果一致。**但是，直接建模$p(x) = \beta_0 + \beta_1 \cdot x$能会产生小于0或大于1的概率，不合理。**
- **对两水平以上的定性响应变量，**不能任意推广。

为什么线性回归不可用



例子：线性回归的default取值，可以认为是属于某一类的**概率的估计**。

但是，如果**直接建模**$p(x) = \beta_0 + \beta_1 \cdot x$，一些数据上概率估计是负的！



4.3. 逻辑斯蒂回归

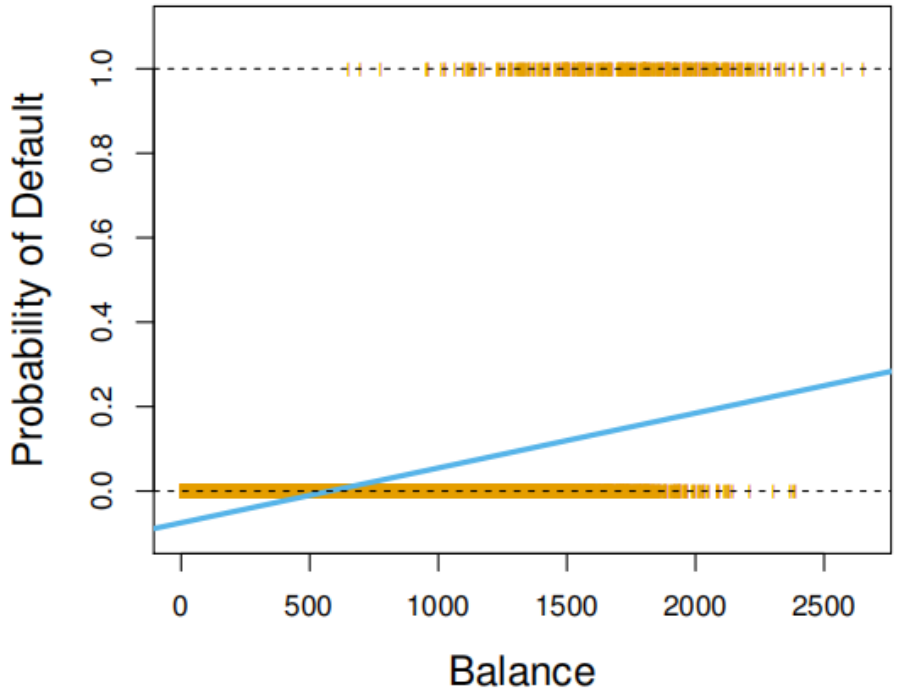
逻辑斯蒂回归（逻辑斯蒂函数）

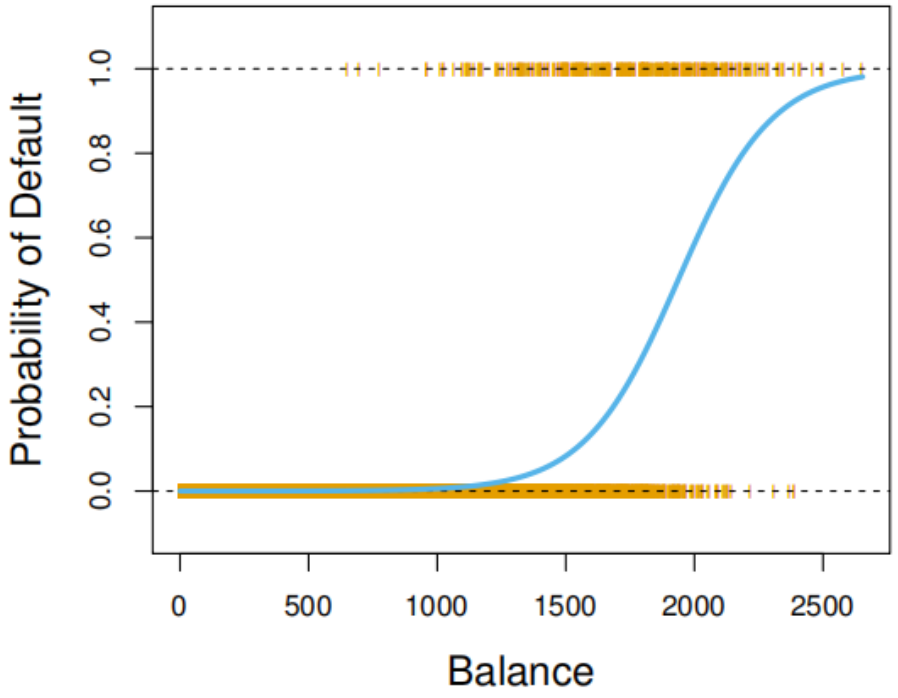
- **逻辑斯谛函数**具有如下形式：

$$p(X) = \frac{e^{\beta_0+\beta_1 X}}{1+e^{\beta_0+\beta_1 X}}$$

（$e \approx 2.71828$是一个数学常量，又称欧拉数Euler's number）

- 容易看出，无论β_0，β_1，X取怎样的值，$p(X)$总是在0到1之间





逻辑斯蒂回归（与函数、与分类）

- **基本想法**：把分类问题转换为回归问题；把分类变量[0,1]视为属于类别1的概率$p(X)$;
- 这时，就能把训练集中的分类数据（定性变量）转为看做概率数据（定量型，虽然只是01两个量值），从而把分类问题转为对概率的回归问题；但是，前面看到，**直接转换为线性回归**问题$p(x) = \beta_0 + \beta_1 X$，回归值可能超出合理范围;
- **一个方案**：用逻辑斯蒂函数用作回归函数，把回归得到概率值限制在合理范围，**新的概率（回归）函数为**:

$$p(X) = \frac{e^{\beta_0+\beta_1 X}}{1 + e^{\beta_0+\beta_1 X}}$$

- 这种情况下：我们把逻辑斯蒂函数的输出作为属于某一类的**概率估计**，**然后**，根据这个概率进行**分类**;
- **逻辑斯蒂回归**把分类问题转为了对属于某一类的概率建模（数学上是回归问题）；
- **系数估计**：把训练集中的数据(X, Pr)代入逻辑斯蒂函数求解β_0和β_1

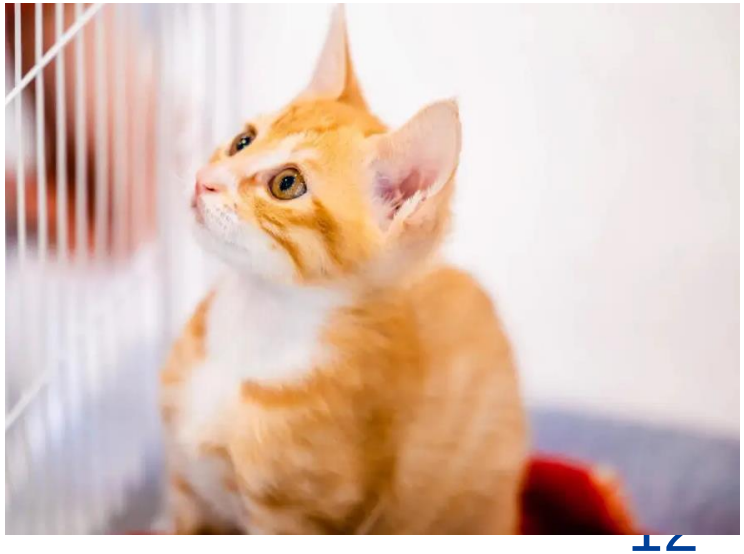
逻辑斯蒂回归（对数发生比）

- 对该公式进行整理并两边同时取对数，得到

$$\log\left\{\frac{p(X)}{1-p(X)}\right\}=\beta_0+\beta_1 X$$

- 等式的左边称为**对数发生比(log-odd)**或**分对数(logit)**。逻辑斯谛回归模型可以视为**分对数变换下关于X的一个线性模型**。
- β_1表示X值每增加一个单位时**对数发生比**的变化，**而不再是**$p(x)$的变化量

回顾一下《线性回归》中对y的各类变换。



逻辑斯蒂回归（系数估计）

- 我们一般采用极大似然方法估计系数

$$\ell(\beta_0, \beta_1) = \prod_{i:y_i=1} p(x_i) \prod_{i:y_i=0} (1 - p(x_i))$$

- **似然(likelihood)**是指观察到这个训练集的概率，如上式。
- 选取可以最大化上式（似然函数）的值(记为：$\hat{\beta}_0, \hat{\beta}_1$)，作为真实值的估计，即：**最大似然估计**。（最小二乘是最大似然估计的一个特例，P93）
- 逻辑斯谛回归和其他一些模型可以很容易通过统计软件的宏软件包拟合。在R软件中，我们使用glm函数。下表建立用balance预测default概率的逻辑斯谛回归模型的系数估计、标准误、假设检验统计量和P值

	Coefficient	Std. Error	Z-statistic	P-value
Intercept	-10.6513	0.3612	-29.5	< 0.0001
balance	0.0055	0.0002	24.9	< 0.0001

$$z = \hat{\beta}_1 / SE(\hat{\beta}_1)$$

逻辑斯蒂回归（预测）

- 当某个人的balance为1000美元时，预测他违约的概率为：

$$\hat{p}(X)=\frac{e^{\hat{\beta}_0+\hat{\beta}_1X}}{1+e^{\hat{\beta}_0+\hat{\beta}_1X}}=\frac{e^{-10.6513+0.0055\times1000}}{1+e^{-10.6513+0.0055\times1000}}=0.006$$

- 但balance为2000美元时

$$\hat{p}(X)=\frac{e^{\hat{\beta}_0+\hat{\beta}_1X}}{1+e^{\hat{\beta}_0+\hat{\beta}_1X}}=\frac{e^{-10.6513+0.0055\times2000}}{1+e^{-10.6513+0.0055\times2000}}=0.586$$

逻辑斯蒂回归（定性变量和哑变量）

- 我们建立用学生身份(student)预测default概率的逻辑斯谛回归模型的系数估计。学生身份用一个哑变量编码，1代表学生，0代表非学生。表中用变量student[Yes]表示。

	Coefficient	Std. Error	Z-statistic	P-value
Intercept	-3.5041	0.0707	-49.55	< 0.0001
student[Yes]	0.4049	0.1150	3.52	0.0004

- $\widehat{\Pr}(\text{default} = \text{Yes} \mid \text{student} = \text{Yes}) = \frac{e^{-3.5041+0.4049\times1}}{1+e^{-3.5041+0.4049\times1}} = 0.0431$
- $\widehat{\Pr}(\text{default} = \text{Yes} \mid \text{student} = \text{No}) = \frac{e^{-3.5041+0.4049\times0}}{1+e^{-3.5041+0.4049\times0}} = 0.0292$

哑变量的系数是正值，且统计显著，说明违约概率确实和是否学生有关；具体结果如上：学生身份更容易违约。



4.3（续） 多元逻辑斯蒂回归

$$\log\left\{\frac{p(X)}{1-p(X)}\right\} = \beta_0 + \beta_1 X + \cdots + \beta_p X_p$$

$$p(X) = \frac{e^{\beta_0+\beta_1 X+\cdots+\beta_p X_p}}{1+e^{\beta_0+\beta_1 X+\cdots+\beta_p X_p}}$$

- 下面是结合balance、 income、 student三个预测变量建立的预测default概率的逻辑斯谛回归模型的系数估计。

	Coefficient	Std. Error	Z-statistic	P-value
Intercept	-10.8690	0.4923	-22.08	< 0.0001
balance	0.0057	0.0002	24.74	< 0.0001
income	0.0030	0.0082	0.37	0.7115
student[Yes]	-0.6468	0.2362	-2.74	0.0062

- 注意：这里student的系数是负的，但单独使用student建模时，系数是正的。
- 而且：这里student的P值是显著的，说明确实是有影响的。（与Advertising例子中的newspaper不同）

一个信用卡余额为1500美元，同时收入40000美元学生的违约率为：

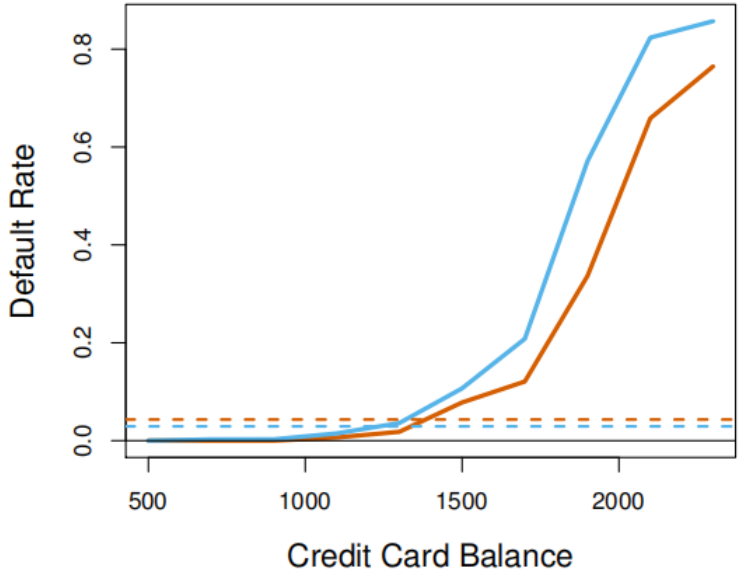
$$\hat{p}(X) = \frac{e^{-10.869+0.00574*1500+0.003*40-0.6468*1}}{1-e^{-10.869+0.00574*1500+0.003*40-0.6468*1}} = 0.058$$

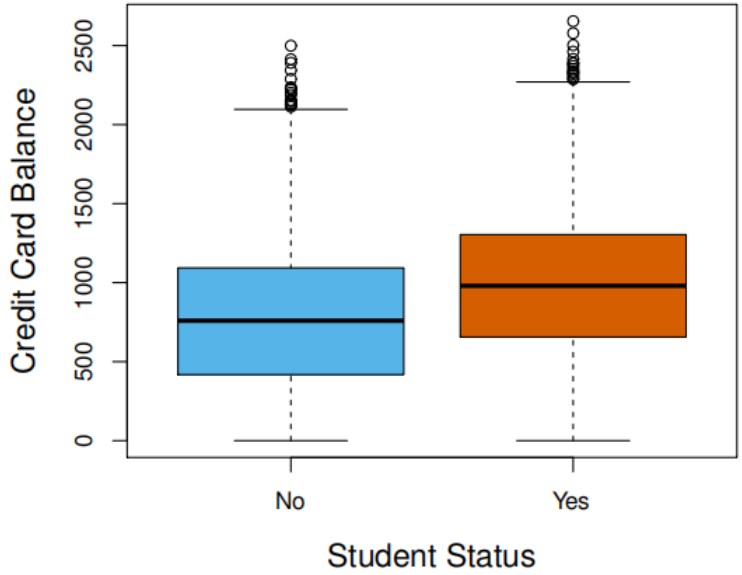
一个信用卡余额为1500美元，同时收入40000美元，但不是学生的违约率为：

$$\hat{p}(X) = \frac{e^{-10.869+0.00574*1500+0.003*40-0.6468*0}}{1-e^{-10.869+0.00574*1500+0.003*40-0.6468*0}} = 0.105$$

混淆现象(Confounding)

- **基本结论**：学生变量是有效的（P值很小），系数是负值，表示综合考虑balance和income的时候学生更不容易发生违约；如下图的左图，学生身份是橙色，非学生身份是蓝色；水平线是考虑所有变量的违约率；
- **混淆现象**的解释：变量student和balance之间有相关性，如右图；学生更有可能会持有大笔的信用卡余额，从而拥有更高的违约率。所以，**只有学生变量一个时**（不考虑balance，一元回归），student的系数为正（因为有更高的balance）；**在考虑balance因素时**（多元回归）， student的系数为负。
- **结合应用**：同等balance下违约率较低，可以贷款给学生，balance别太高

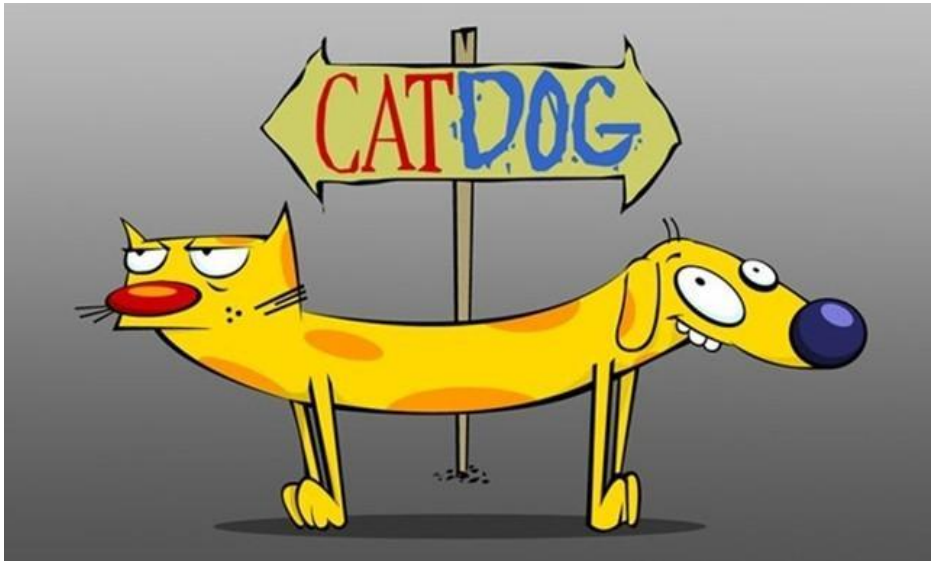




混淆现象(Confounding)

- 使用一个预测变量做逻辑斯蒂回归时，如果**其他预测变量与之有关系**，那么模型会存在风险；
- 与线性回归一样，只用一个预测变量得到的结果可能与多个预测变量得到的**结果完全不一样**，尤其是当这些因素之间存在**相关性**时更是如此；
- 这种现象称为**混淆现象**。





4.3（续） 其他问题

逻辑斯谛回归（分类数大于2）

- 目前我们讨论的逻辑斯谛回归响应变量的取值为**两类**，但很容易将其推广到**多类**情况。模型具有下面形式（可以用R软件中glmnet包计算）

$$\Pr(Y = k \mid X) = \frac{e^{\beta_{0k}+\beta_{1k}X_1+\cdots+\beta_{pk}X_p}}{\sum_{\ell=1}^{K} e^{\beta_{0\ell}+\beta_{1\ell}X_1+\cdots+\beta_{p\ell}X_p}}$$

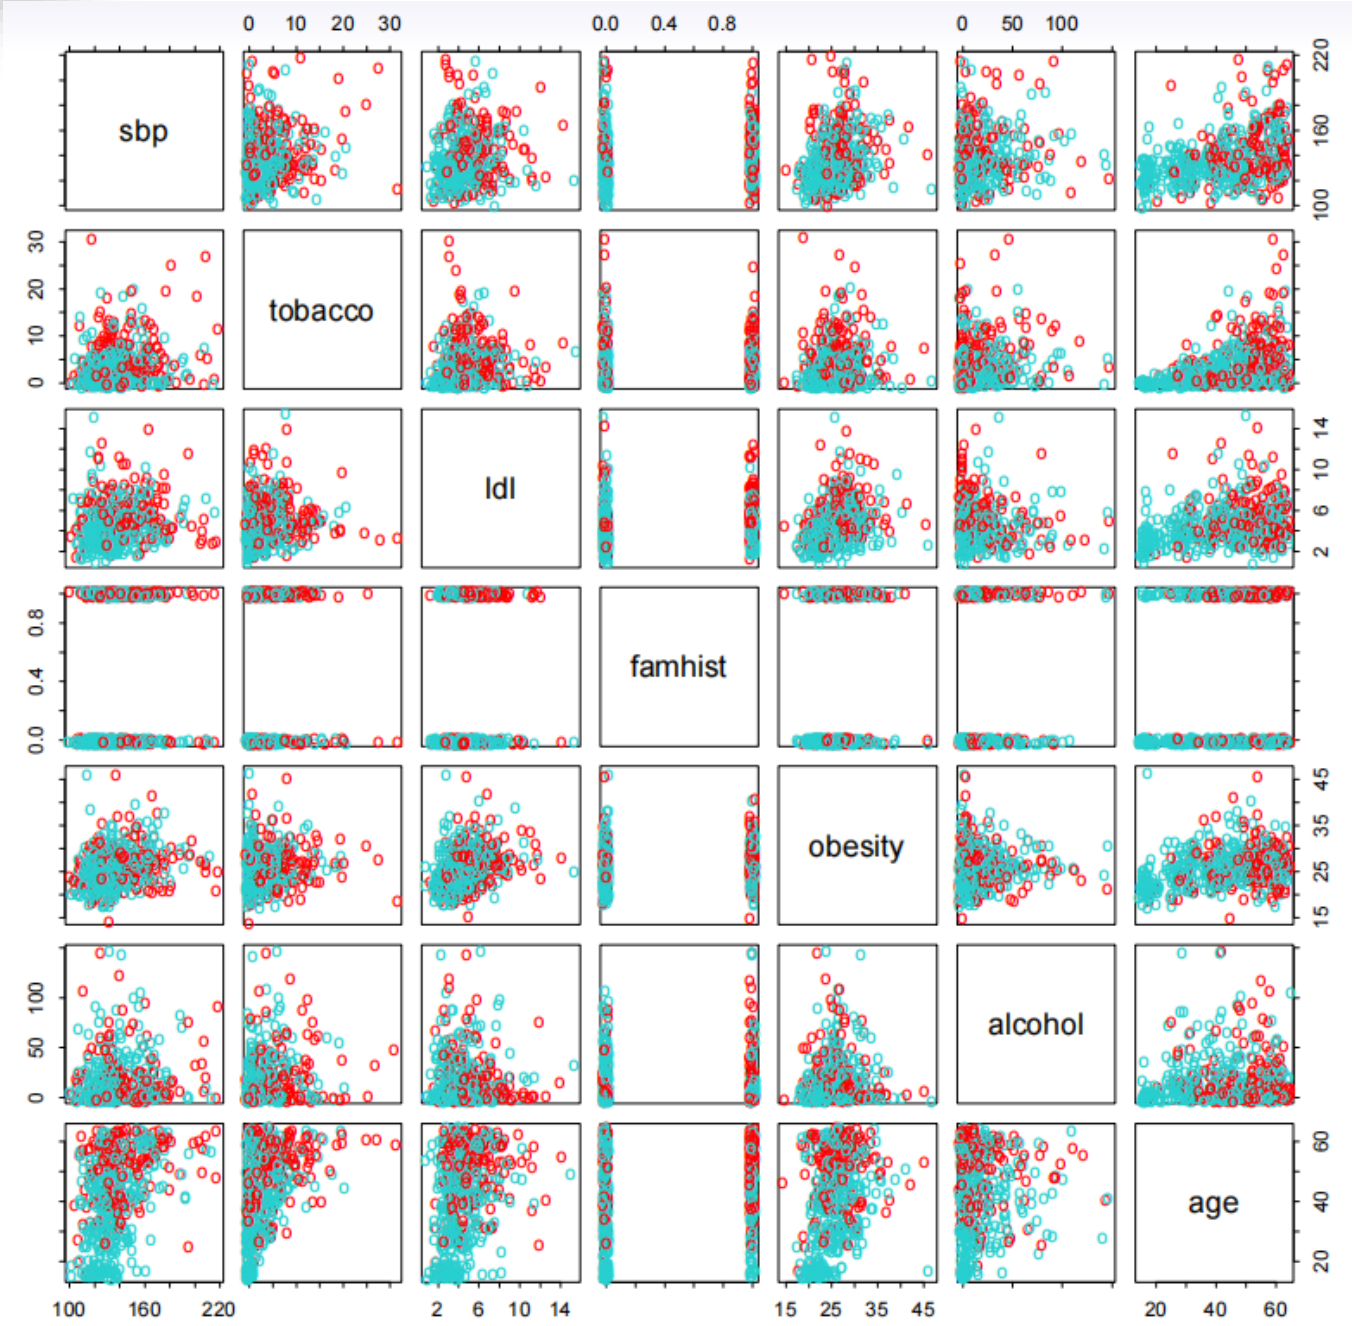
- 这里**每一类**都有**一个线性函数与之对应**，用以判断属于这一类的概率（或不属于这一类的概率）

- 多类逻辑回归也称为**多项式回归(multinomial regression)**。

参数修正：南非心脏病数据集

- 160例心肌梗塞(myocardial infarction，MI)病例和302例对照(controls)（所有年龄范围在15-64岁之间，男性），来自80年代初的南非西开普省。
- 该地区的总体流行率非常高：5.1%。
- 该数据集对七个预测变量（风险因素）进行测量，见下页散点图矩阵(scatterplot matrix)。
- 目标是确定风险的相对强度和方向（即正/负相关）。
- 这是某研究的一部分，旨在教育公众更健康的饮食。

参数修正：南非心脏病数据集



- 南非心脏病数据的散点图矩阵。
- 响应变量采用颜色编码——MI病例为红色，对照组为青绿色。
- famhist是一个二元预测变量，1 表示有MI患病家族史。

sbp:收缩压、tabacco吸烟、ldl低密度脂蛋白、famhist家族病史、obesity肥胖、alcohol饮酒

参数修正：南非心脏病数据集


```
> heartfit<-glm(chd~.,data=heart,family=binomial)
> summary(heartfit)

Call:
glm(formula = chd ~ ., family = binomial, data = heart)

Coefficients:
                  Estimate Std. Error z value Pr(>|z|)
(Intercept)     -4.1295997  0.9641558  -4.283 1.84e-05 ***
sbp              0.0057607  0.0056326   1.023  0.30643
tobacco          0.0795256  0.0262150   3.034  0.00242 **
ldl              0.1847793  0.0574115   3.219  0.00129 **
famhistPresent   0.9391855  0.2248691   4.177 2.96e-05 ***
obesity         -0.0345434  0.0291053  -1.187  0.23529
alcohol          0.0006065  0.0044550   0.136  0.89171
age              0.0425412  0.0101749   4.181 2.90e-05 ***

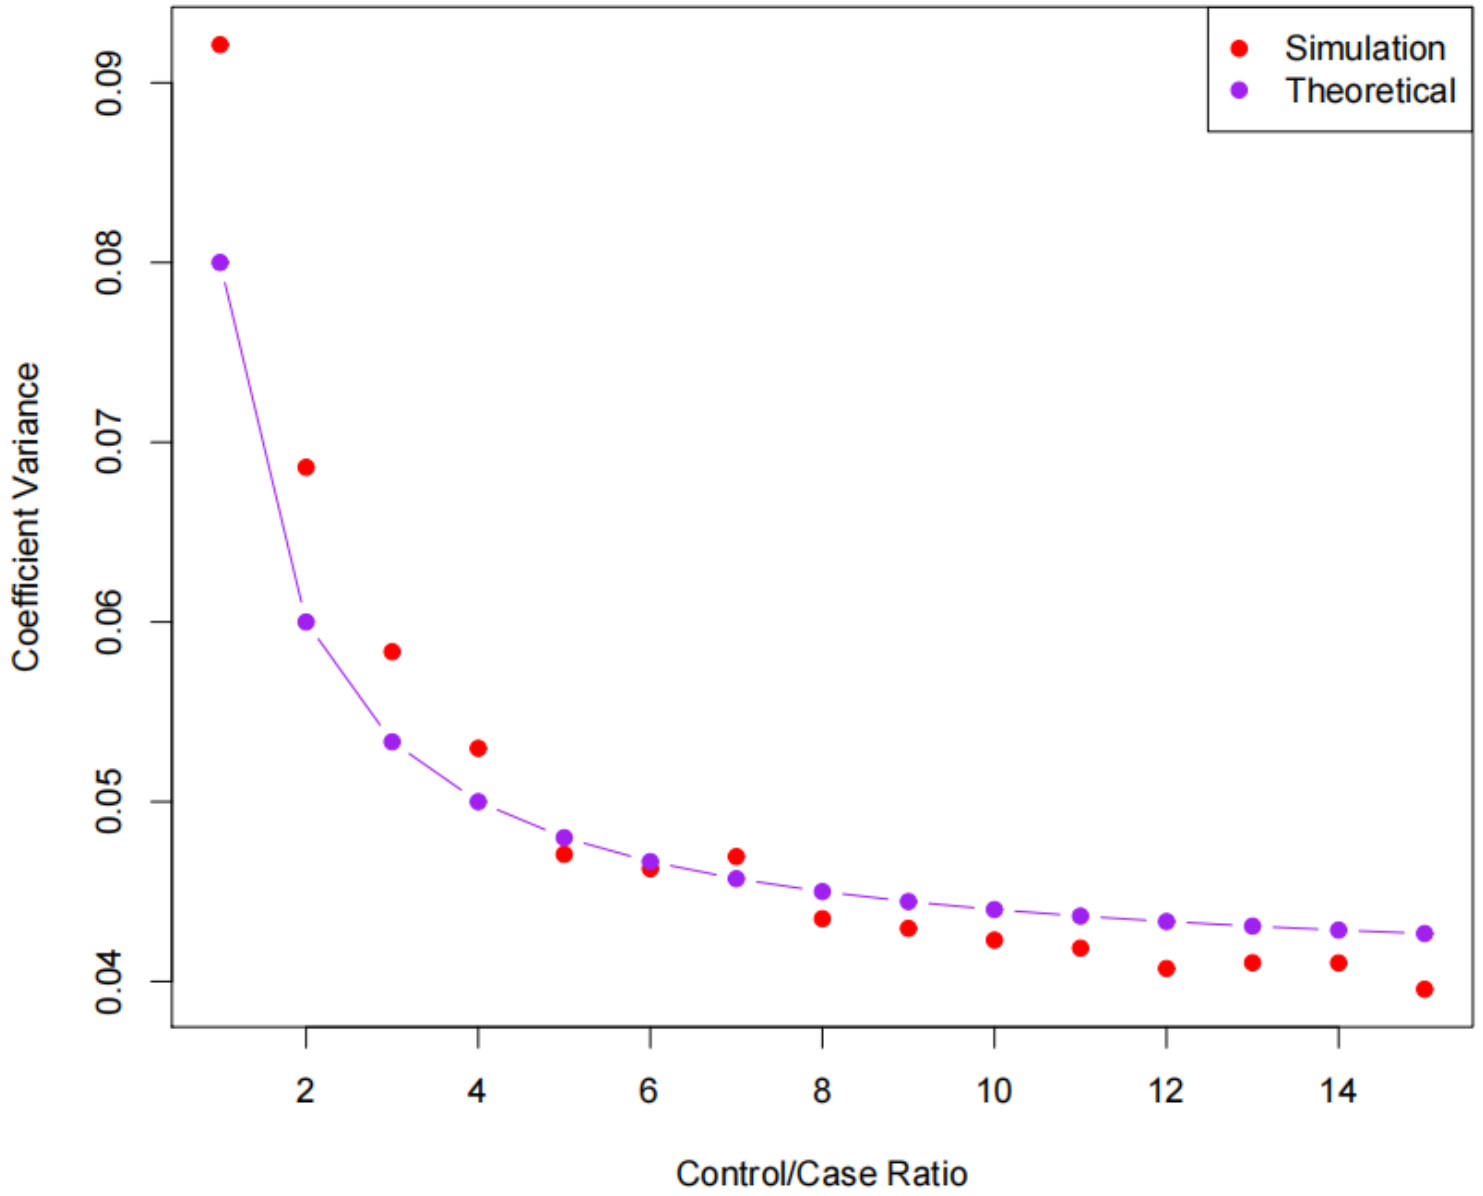
(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 596.11  on 461  degrees of freedom
Residual deviance: 483.17  on 454  degrees of freedom
AIC: 499.17
```

- 在心脏病数据中，有160个病例，302个对照——因此样本中的患病率是$\tilde{\pi} = 0.35$。
- 然而，该地区MI的患病率是$\pi = 0.05$。使用病例和对照样本，我们可以准确地估计回归参数$\hat{\beta}_j$（如果我们的模型是正确的）；
- 但常数项$\hat{\beta}_0$不正确，$\hat{\beta}_0$主要用于调节平均拟合概率与真实数据实际发生的比例。（P94, 4.3.2最后一句话）
- 我们可以通过一个简单的变换来修正估计的截距

$$\hat{\beta}_0^* = \hat{\beta}_0 + \log\frac{\pi}{1-\pi} - \log\frac{\tilde{\pi}}{1-\tilde{\pi}}$$

- MI病例组很少，所以我们需要全部考虑；但使用多少对照组，是需要考虑的（见下页）



- 用于对照的病例样本比MI病例更多，可以减少参数估计的方差。
- 但是在大约5:1的比率之后，方差减少趋于平缓。

不平衡二元数据中的收益递减

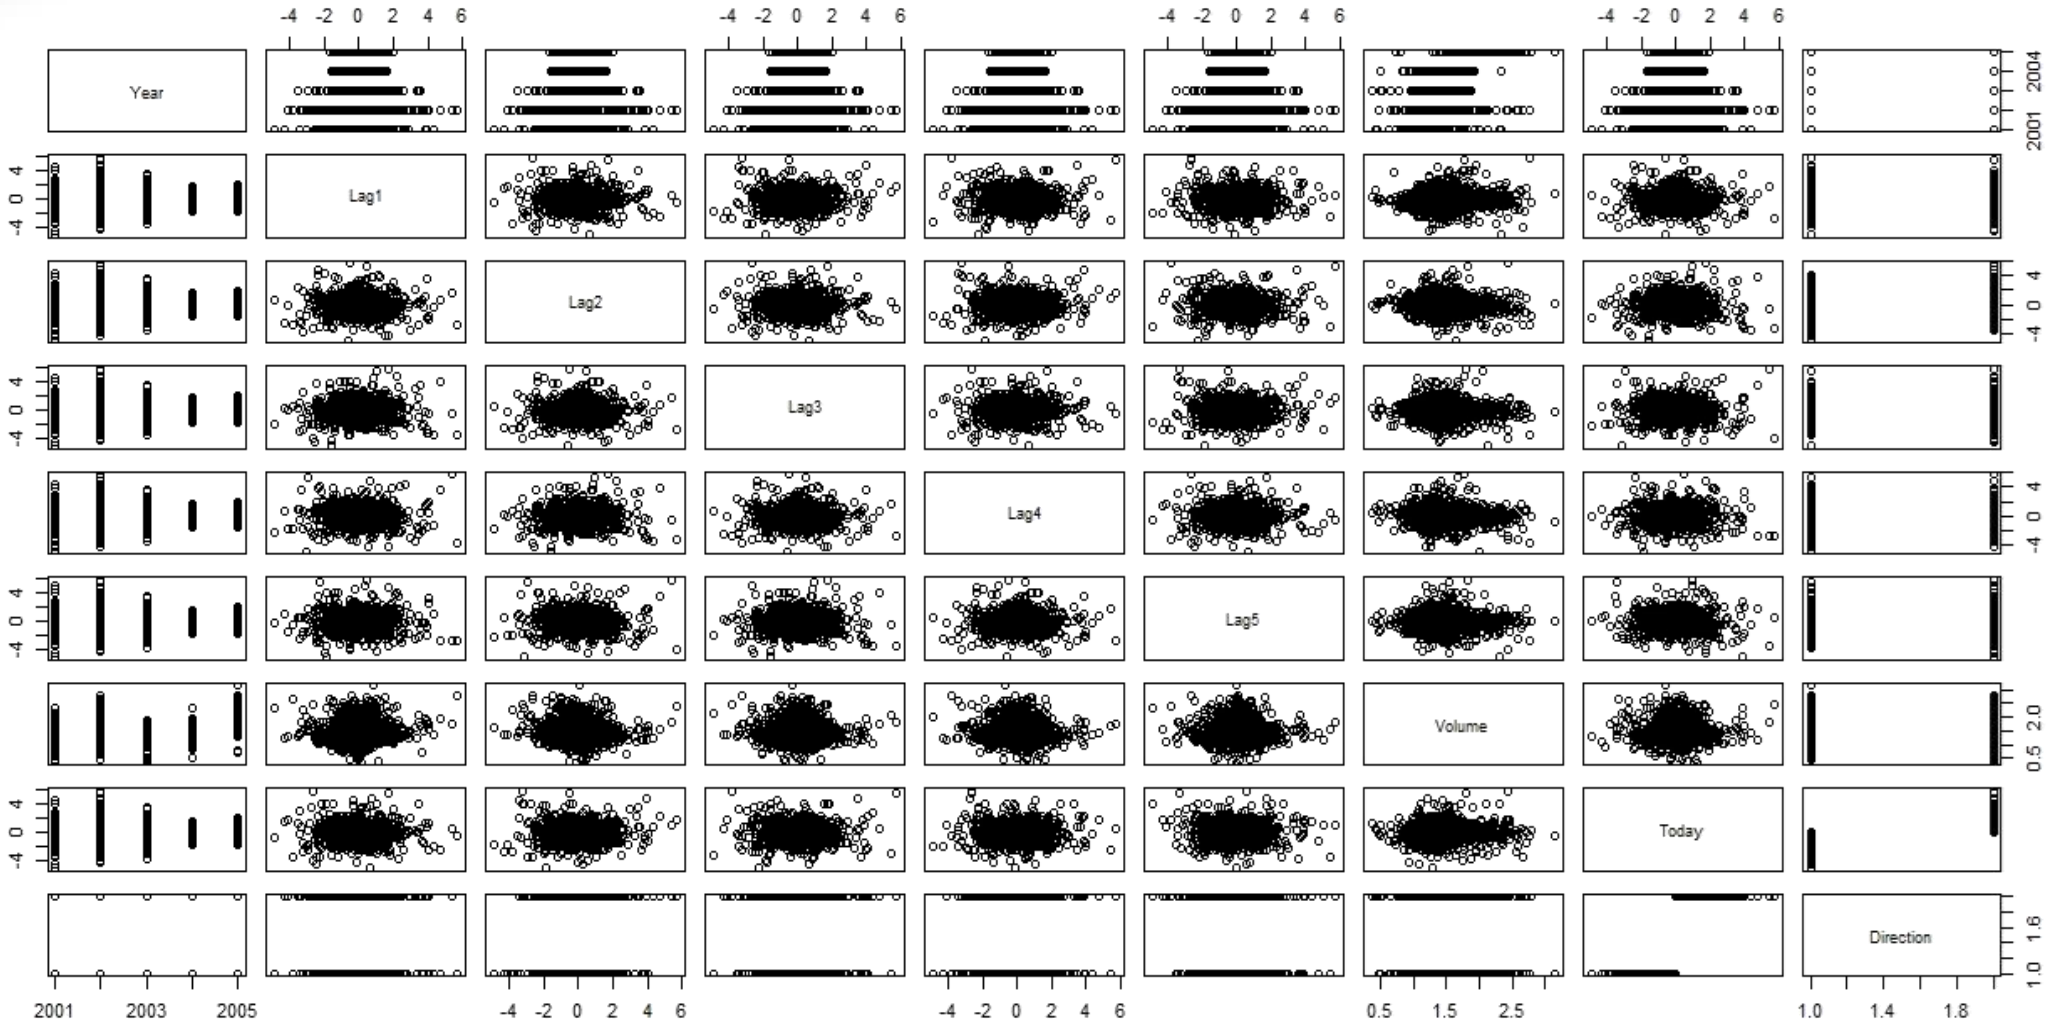
4.3（续） R实验示例

R实验：逻辑斯蒂回归 （P107）


```
> library(ISLR)
> names(Smarket)
[1] "Year"      "Lag1"      "Lag2"      "Lag3"      "Lag4"      "Lag5"      "Volume"    "Today"     "Direction"
> dim(Smarket)
[1] 1250    9
> summary(Smarket)
      Year          Lag1                Lag2                Lag3                Lag4                Lag5              Volume          Today          Direction
 Min.   :2001   Min.   :-4.922000   Min.   :-4.922000   Min.   :-4.922000   Min.   :-4.922000   Min.   :-4.92200   Min.   :0.3561   Min.   :-4.922000   Down:602
 1st Qu.:2002   1st Qu.:-0.639500   1st Qu.:-0.639500   1st Qu.:-0.640000   1st Qu.:-0.640000   1st Qu.:-0.64000   1st Qu.:1.2574   1st Qu.:-0.639500   Up  :648
 Median :2003   Median : 0.039000   Median : 0.039000   Median : 0.038500   Median : 0.038500   Median : 0.03850   Median :1.4229   Median : 0.038500
 Mean   :2003   Mean   : 0.003834   Mean   : 0.003919   Mean   : 0.001716   Mean   : 0.001636   Mean   : 0.00561   Mean   :1.4783   Mean   : 0.003138
 3rd Qu.:2004   3rd Qu.: 0.596750   3rd Qu.: 0.596750   3rd Qu.: 0.596750   3rd Qu.: 0.596750   3rd Qu.: 0.59700   3rd Qu.:1.6417   3rd Qu.: 0.596750
 Max.   :2005   Max.   : 5.733000   Max.   : 5.733000   Max.   : 5.733000   Max.   : 5.733000   Max.   : 5.73300   Max.   :3.1525   Max.   : 5.733000
> pairs(Smarket)
```

首先对ISLR库的smarket（股票市场）数据的数值和图像进行描述统计分析。该数据集里包括从2001年年初至2005年年末1250天里S&P500股票指数的投资回报率。数据中记录了过去5个交易日中的每个交易日的投资回报率，从Lag1到Lag5，同时也记录了Volume(前一日股票成交量，单位为十亿)，Today（当日的投资回报率）以及Direction（这些数据在市场的走势方向，或Up(涨)或Down(跌)）。

R实验：逻辑斯蒂回归



- pairs(Smarket)命令绘制出的变量散点图。

R实验：逻辑斯蒂回归

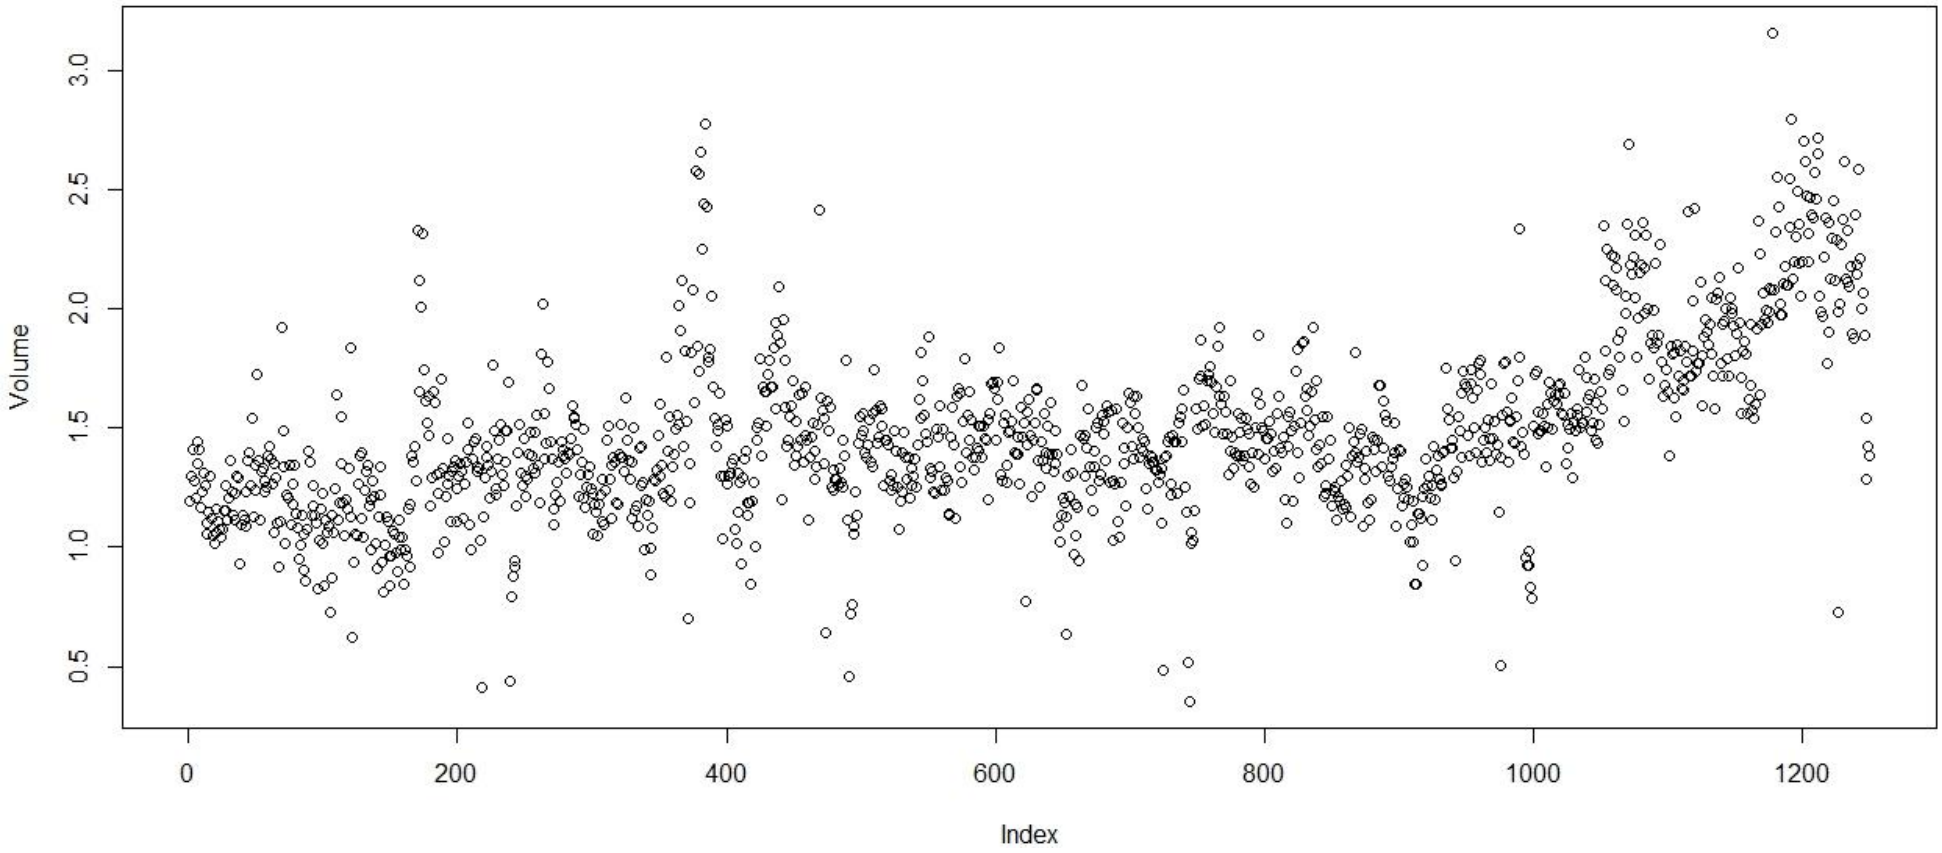

```
> cor(Smarket)

Error in cor(Smarket): 'x' 必需是数值
Show stack trace
> cor(Smarket[,-9])
             Year         Lag1         Lag2         Lag3         Lag4         Lag5       Volume        Today
Year   1.00000000  0.029699649  0.030596422  0.033194581  0.035688718  0.029787995  0.53900647  0.030095229
Lag1   0.02969965  1.000000000 -0.026294328 -0.010803402 -0.002985911 -0.005674606  0.04090991 -0.026155045
Lag2   0.03059642 -0.026294328  1.000000000 -0.025896670 -0.010853533 -0.003557949 -0.04338321 -0.010250033
Lag3   0.03319458 -0.010803402 -0.025896670  1.000000000 -0.024051036 -0.018808338 -0.04182369 -0.002447647
Lag4   0.03568872 -0.002985911 -0.010853533 -0.024051036  1.000000000 -0.027083641 -0.04841425 -0.006899527
Lag5   0.02978799 -0.005674606 -0.003557949 -0.018808338 -0.027083641  1.000000000 -0.02200231 -0.034860083
Volume 0.53900647  0.040909908 -0.043383215 -0.041823686 -0.048414246 -0.022002315  1.00000000  0.014591823
Today  0.03009523 -0.026155045 -0.010250033 -0.002447647 -0.006899527 -0.034860083  0.01459182  1.000000000
```

- cor()函数可以计算所有预测变量两两之间相关系数的矩阵。下面第一行命令运行错误，是因为Direction变量是定性的。cor(Smarket[, -9])，负号表示去除该列。
- 可见：前几日的投资回报之间，以及与当日的投资回报之间的相关系数接近零。
- Volume与Year有关，也即，Volume随着Year的增长而增长，说明股票市场的繁荣。

R实验：逻辑斯蒂回归


```
> attach(Smarket)
> plot(Volume)
```



通过画图可以观察到从2001年至2005年，Volume即平均每日股票成交量随时间一直增长。

R实验：逻辑斯蒂回归


```
> glm.fit = glm(Direction~Lag1+Lag2+Lag3+Lag4+Lag5+Volume, data = Smarket, family = binomial)
> summary(glm.fit)

Call:
glm(formula = Direction ~ Lag1 + Lag2 + Lag3 + Lag4 + Lag5 +
    Volume, family = binomial, data = Smarket)

Deviance Residuals:
   Min      1Q  Median      3Q     Max
-1.446  -1.203   1.065   1.145   1.326

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept) -0.126000   0.240736  -0.523    0.601
Lag1        -0.073074   0.050167  -1.457    0.145
Lag2        -0.042301   0.050086  -0.845    0.398
Lag3         0.011085   0.049939   0.222    0.824
Lag4         0.009359   0.049974   0.187    0.851
Lag5         0.010313   0.049511   0.208    0.835
Volume       0.135441   0.158360   0.855    0.392

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 1731.2  on 1249  degrees of freedom
Residual deviance: 1727.6  on 1243  degrees of freedom
AIC: 1741.6

Number of Fisher Scoring iterations: 3
```

- 接下来，通过Lag1到Lag5和Volume 拟合逻辑斯谛回归模型来预测Direction。
- glm ()函数用于拟合广义线性模型(generalized linear model)，其中包含了逻辑斯谛回归模型。glm()函数的用法与lm()类似，**不同在于**必须输人如下参数**设置family= binomial**。该命令的功能是请求R软件执行**逻辑斯谛回归**，不使用其他类型的广义线性模型。

R实验：逻辑斯蒂回归


```
> glm.fit = glm(Direction~Lag1+Lag2+Lag3+Lag4+Lag5+Volume, data = Smarket, family = binomial)
> summary(glm.fit)

Call:
glm(formula = Direction ~ Lag1 + Lag2 + Lag3 + Lag4 + Lag5 +
    Volume, family = binomial, data = Smarket)

Deviance Residuals:
   Min      1Q  Median      3Q     Max
-1.446  -1.203   1.065   1.145   1.326

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept) -0.126000   0.240736  -0.523    0.601
Lag1        -0.073074   0.050167  -1.457    0.145
Lag2        -0.042301   0.050086  -0.845    0.398
Lag3         0.011085   0.049939   0.222    0.824
Lag4         0.009359   0.049974   0.187    0.851
Lag5         0.010313   0.049511   0.208    0.835
Volume       0.135441   0.158360   0.855    0.392

(Dispersion parameter for binomial family taken to be 1)
    Null deviance: 1731.2  on 1249  degrees of freedom
Residual deviance: 1727.6  on 1243  degrees of freedom
AIC: 1741.6

Number of Fisher Scoring iterations: 3
```

- 这里最小的p值是Lag1的系数。预测变量负的系数表明如果市场昨天的投资回报率是正的，那么今日市场可能不会上涨。
- 然而，**p值0.15仍然是比较大的**，所以没有充分的证据表明Lag1和Direction之间有确切的关联。
- 调用coef()函数可获取拟合模型的系数，同时也可以用summary()函数来获取拟合模型的其他方面的信息，比如系数的p值。

R实验：逻辑斯蒂回归


```
> glm.probs = predict(glm.fit, type="response")
> glm.probs[1:10]
        1         2         3         4         5         6         7         8
0.5070841 0.4814679 0.4811388 0.5152224 0.5107812 0.5069565 0.4926509 0.5092292
        9        10
0.5176135 0.4888378
> contrasts(Direction)
     Up
Down  0
Up    1
```

- predict ()函数可用来预测在给定预测变量值下市场上涨的概率。选项type **="response"是明确告诉R输出概率P**(Y=1 | X)，而不必输出其他信息，比如分对数。
- 如果**不能提供数据集**给predict()函数，那么它会**计算**拟合逻辑斯谛回归模型的**训练数据的概率**。这里，输出前10个预测概率。
- 这些值对应的是市场上涨而不是下跌的概率，因为**contrasts ()函数表明R创建了一个哑变量，1代表Up (上涨)**。

R实验：逻辑斯蒂回归


```
> glm.pred = rep("Down", 1250)
> glm.pred[glm.probs>.5] = "Up"
```

- 为预测特定某一天市场上涨还是下跌，必须将预测的概率转化为类别，Up或Down。上面两行命令建立了一个类向量预测，以预测的市场上涨概率比0. 5大还是小为依据。
- 第一行命令创建了一个由1250个Down元素组成的向量。
- 第二行将预测市场上涨概率超过0.5的元素转变为Up。对这些预测，table ()函数可以产生混淆矩阵来判断有多少观测被正确或错误分类了。

```
> table(glm.pred, Direction)
         Direction
glm.pred Down  Up
    Down  145 141
    Up    457 507
> (507 + 145) / 1250
[1] 0.5216
> mean(glm.pred == Direction)
[1] 0.5216
```

- 混淆矩阵中对角线元素表示正确的预测，而非对角线元素代表了错误的预测。
- 由此可知模型正确预测了市场在507天里上涨，在145天里下跌，总共507 +145 =652天正确预测。mean()函数可以计算正确预测的比例。在这种情况下，逻辑斯谛回归正确预测了市场52.2%时间的动向变化。（训练数据集一致）

R实验：逻辑斯蒂回归


```
> train = (Year<2005)
> Smarket.2005 = Smarket[!train,]
> dim(Smarket.2005)
[1] 252   9
> Direction.2005 = Direction[!train]
```

- 为达到这个目的，首先建立一个向量表示2001年至2004年之间的观测，然后由这个向量定义余下的 2005 年观测数据集。

```
> glm.fit = glm(Direction~Lag1 + Lag2 + Lag3 + Lag4 + Lag5 + Volume, data = Smarket, family = binomial, subset = train)
> glm.probs = predict(glm.fit, Smarket.2005, type = "response")
```

- 现在，根据subset参数对2005年之前的观测数据的子集拟合一个逻辑斯谛回归模型。得到测试集中每一天的股票市场上涨的预测概率，即2005年的每天。

```
> glm.pred = rep("Down", 252)
> glm.pred[glm.probs>.5] = "Up"
> table(glm.pred, Direction.2005)
        Direction.2005
glm.pred Down Up
    Down   77 97
    Up     34 44
> mean(glm.pred == Direction.2005)
[1] 0.4801587
> mean(glm.pred != Direction.2005)
[1] 0.5198413
```

- 注意到训练和测试模型是在两组完全独立的数据集上：训练只是用2005年之前的数据,而测试则是使用2005年的数据。最后计算出2005年的预测并与真实的市场走势做比较。
- 符号!=表示不等，所以最后一行的命令是计算测试错误率。结果比较令人失望:测试错误率为52%，比随机猜想更糟糕！

R实验：逻辑斯蒂回归


```
> glm.fit = glm(Direction~Lag1 + Lag2, data = Smarket, family = binomial, subset = train)
> glm.probs = predict(glm.fit, Smarket.2005, type = "response")
> glm.pred = rep("Down", 252)
> glm.pred[glm.probs>.5] = "Up"
> table(glm.pred, Direction.2005)
        Direction.2005
glm.pred Down  Up
    Down   35  35
    Up     76 106
> mean(glm.pred == Direction.2005)
[1] 0.5595238
> 106 / (106 + 76)
[1] 0.5824176
```

- 加入与响应变量无关的预测变量会造成测试错误率的增大(因为这样的预测变量会增大模型方差，但不会相应地降低模型偏差)，所以去除这样的预测变量可能会优化模型。
- 重新拟合逻辑斯谛回归模型，只用Lag1和Lag2两个预测变量，因为它们在原逻辑斯谛回归模型中表现出了最佳的预测能力（P值稍小）。
- 现在的结果改进了：56%的市场动向能够被正确预测。混淆矩阵表明当用逻辑斯谛回归模型预测市场下跌时，只有50%正确率；而当预测市场上涨时，准确率有58%。

R实验：逻辑斯蒂回归

- 下面的程序是在特定的Lag1和Lag2值下预测投资回报率。例如，当Lag1和Lag2分别为1.2和1.1时与分别为1.5和-0.8时，这里运用predict ()函数预测Direction。

```
> predict(glm.fit, newdata = data.frame(Lag1 = c(1.2, 1.5), Lag2 = c(1.1, -0.8)), type = "response")
        1         2
0.4791462 0.4960939
```



4.4. 线性判别分析

- 在二元响应变量的情况下，逻辑斯蒂回归根据逻辑斯蒂函数**直接建立**$\Pr(Y = k \mid X = x)$模型（模型的参数采用**最大似然估计**获得）
- 现在考虑另外一类间接估计概率$\Pr(Y = k \mid X = x)$的方法。在这类方法中，**首先**分别对每种响应分类（给定的Y）建立预测变量X的分布模型(“先验知识”)，**然后**运用**贝叶斯定理(Bayes theorem)**反过来估计$\Pr(Y = k \mid X = x)$（“后验概率”）。
- **假设**这些分布是正态分布时，则模型在形式上与逻辑斯谛回归很相似。但这种方法是**通用**的，也可以用于其它分布。我们接下来将集中讨论正态分布的情况。

为什么进行判别分析?

- 当**类别的区分度高**的时候，逻辑斯谛回归模型的参数估计不够稳定，这点在线性判别分析中是不存在的。

- 如果**样本量n比较小**，而且在每一类响应分类中预测变量X近似服从正态分布，那么线性判别分类模型比逻辑斯谛回归模型更稳定。

- **响应分类多于两类时**，线性判别分析应用更普遍。



4.4.1 运用贝叶斯定理进行分类

贝叶斯定理（回顾）

- 假设定性变量Y有K类，设$\pi_k = \Pr(Y = k)$为一个随机选择的Y属于第k类的**先验(prior)概率（即：Y的分布）；**
- 设$f_k(x) = \Pr(X = x \mid Y = k)$为第$k$类观测（指Y）**的$X$的密度函数(density function)**
- 在上述背景下，贝叶斯定理（后验概率）表述为：

$$\Pr(Y = k \mid X = x) = \frac{f_k(x)\pi_k}{\sum_{l=1}^{K} \pi_l f_l(x)}$$

上式即表示待分类变量x属于第k类的概率，是**后验概率**。

- 待分类变量x属于第k类的概率，也即**后验概率**，为：

$$\Pr(Y = k \mid X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^{K} \pi_l f_l(x)}$$

把上式记为：$p_k(x) = \Pr(Y = k \mid X = x)$。前文可知，贝叶斯分类器将$x$分类到$p_k(x)$最大的一类，在所有分类器中误差最小。

如何提升上式的准确性，以进一步保证后续分类的准确性呢？

①**π_k一般较容易估计**，取Y的随机抽样，计算π_k即可。

②对$f_k(x)$的估计更为复杂，为第k类观测（指Y）的X的**密度函数(density function)**，是后续内容的重点。



4.4.2 p=1的线性判别分析

- 即：p=1，只有1个变量；对类别的数量并无要求；
- 重点是估计 $f_k(x)$，指第k类观测（指Y）的X的**密度函数(density function)**；
- 假设$f_k(x)$是正态的(normal)或高斯的(Gaussian)；也即：不同类别的x服从均值不同(μ_k)，方差相同(σ^2)的正态分布；
  - 在一维的情况下，正态密度函数的形式为：

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} e^{-\frac{1}{2}\left(\frac{x-\mu_k}{\sigma_k}\right)^2}$$

  - 其中μ_k和σ_k^2是第k类的平均值和方差。我们假设$\sigma_1^2 = \cdots = \sigma_k^2$，简记$\sigma^2$

- 将其代入贝叶斯公式$p_k(x) = \Pr(Y = k \mid X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^{K} \pi_l f_l(x)}$，化简得：

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_k}{\sigma}\right)^2}}{\sum_{l=1}^{K} \pi_l \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_l}{\sigma}\right)^2}}$$

- **贝叶斯分类器**将观测$X = x$分到上式计算的最大的一类（即：某个k值）；
- 只看分子即可；对上式取对数，整理可以看出，贝叶斯分类器将观测分到

$$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)$$

最大的一组。

这里$\delta_k(x)$是关于x的一个**线性函数，所以叫线性判别分析。**（线性判别的“线性”）

- 例如，假设$K = 2$且$\pi_1 = \pi_2 = 0.5$，那么此时贝叶斯**决策边界 (decision boundary)**对应的点为：

$$\text{决策边界：}\ \delta_1(x) = \delta_2(x)$$

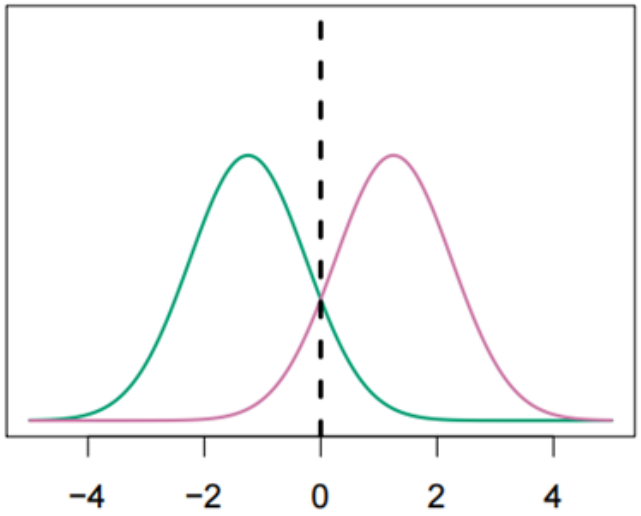
$$x \cdot \frac{\mu_1}{\sigma^2} - \frac{\mu_1^2}{2\sigma^2} + \log(\pi_1) = x \cdot \frac{\mu_2}{\sigma^2} - \frac{\mu_2^2}{2\sigma^2} + \log(\pi_2)$$

$$2x(\mu_1 - \mu_2) = \mu_1^2 - \mu_2^2$$

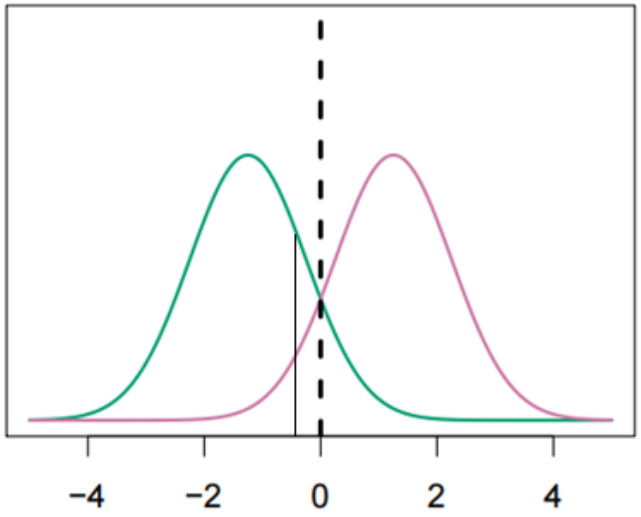
$$x = \frac{\mu_1 + \mu_2}{2}$$

线性判别分析 (根据概率密度分类)

π_1=.5, π_2=.5



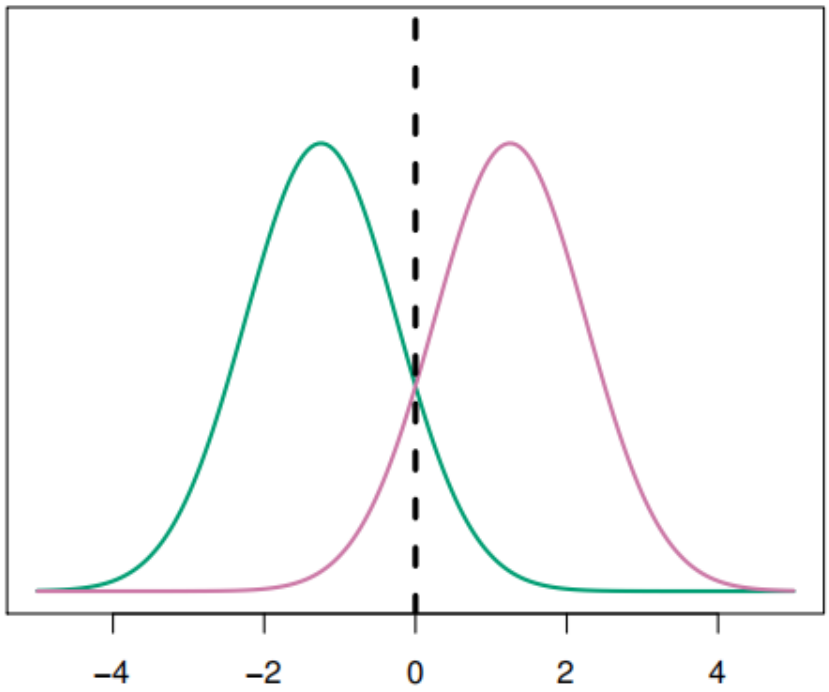
π_1=.3, π_2=.7

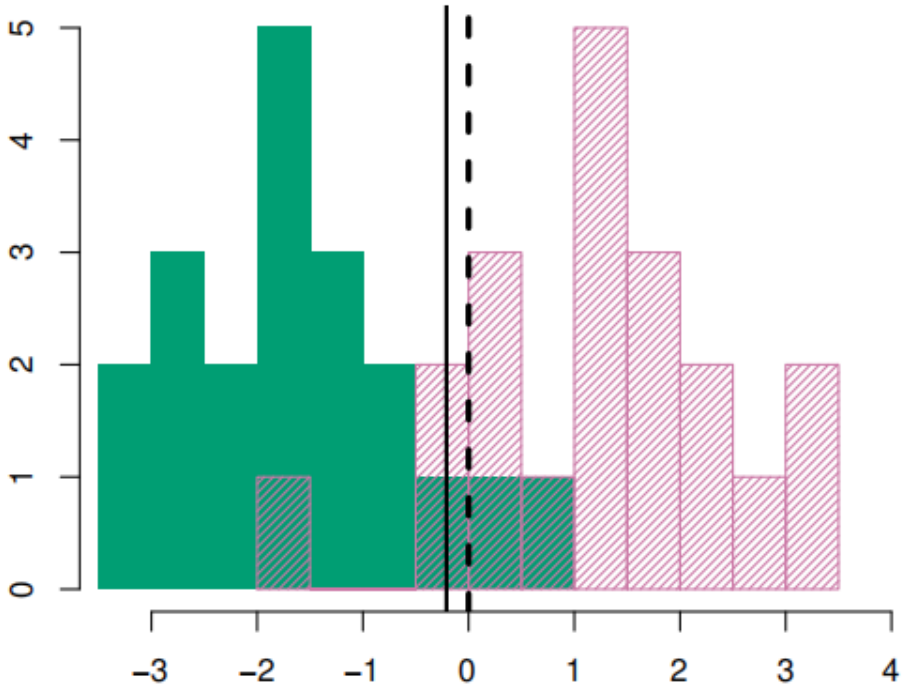


$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_k}{\sigma}\right)^2}}{\sum_{l=1}^{K} \pi_l \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_l}{\sigma}\right)^2}}$$

- **先验概率π_k相同**，根据概率密度的大小将一个数据点进行分类。
- 但当**先验概率不同时**，我们需要考虑先验概率的影响，比较$\pi_k f_k(x)$。右图中，我们倾向于将点分类到粉色类中，因为考虑先验概率（紫色类的结果更多，系数为0.7）后，决策边界会**左移**（加项$\log(\pi_k)$紫色0.7更大，所以决策所需x更小）

线性判别分析 (根据概率密度分类)





- 示例：两个密度函数的**均值与方差**分别为$\mu_1 = -1.5, \mu_2 = 1.5, \pi_1 = \pi_2 = 0.5, \sigma^2 = 1$
- 通常我们并不知道这些参数，因为我们**只有训练数据**。这种情况下，我们需要对这些参数进行估计（右图，实线是根据训练数据估计的决策边界，虚线是实际的决策边界）。

线性判别分析 (相关参数的估计)

$$\hat{\pi}_k = \frac{n_k}{n}$$

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} x_i$$

$$\hat{\sigma}^2 = \frac{1}{n-K} \sum_{k=1}^{K} \sum_{i:y_i=k} (x_i - \hat{\mu}_k)^2 \qquad = \sum_{k=1}^{K} \frac{n_k - 1}{n-K} \cdot \hat{\sigma}_k^2$$

LDA的假设：$\sigma_1^2 = \cdots = \sigma_k^2$，简记$\sigma^2$

- 这里$\hat{\sigma}_k^2 = \frac{1}{n_k - 1} \sum_{i:y_i=k} (x_i - \hat{\mu}_k)^2$是估计第$k$类方差常用的公式，$n$为观测的总量，$n_k$为属于第$k$类的观测量。



线性判别分析 (与贝叶斯分类器对比)

- LDA分类器的假设：各类样本对应的x是来自均值不同、方差相同（均为σ^2）的正态分布
- 二者关系：基于上述假设，将相关的参数估计和概率分布代入贝叶斯分类器（后验概率）中，即为LDA分类器
- 某种程度上：LDA可视为是“样本对应的x的概率密度函数为正态分布的情况下的贝叶斯分类器的化简”，或认为是“朴素贝叶斯分类器在特征X是连续值场景下的推广”

清华学生的一篇博客：

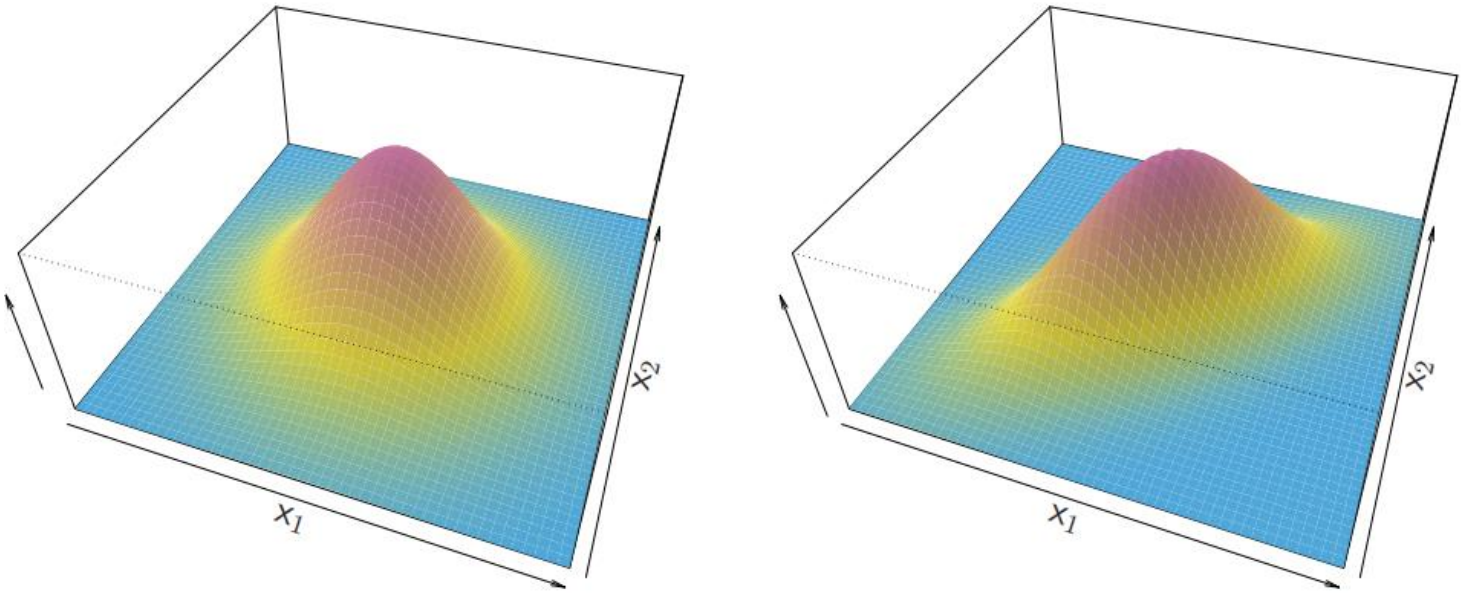
https://truenobility303.github.io/Bayes-Classifier/



4.4.3 p>1的线性判别分析

p>1的线性判别分析

- LDA推广到多元：假设X=(X_1, X_2, …X_p)服从一个**均值不同**、**协方差矩阵相同**的**多元高斯分布**。
- 多元高斯分布假设每一个预测变量服从一个一维**正态分布**，且每两个有预测变量之间都存在一些**相关性**。
- p=2，左图：两个预测变量之间是不相关的，Cor (X_1, X_2)=0。右图：两个变量之间的相关系数为0.7；



p>1的线性判别分析

- **多元高斯分布**密度函数：$f(x)=\frac{1}{(2\pi)^{p/2}|\Sigma|^{\frac{1}{2}}}e^{-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)}$

- 在预测变量的维度p>1的情况下，LDA分类器假设第 k 类观测的 x 服从一个多元高斯分布$N(\mu_k,\sum)$，其中μ_k是一个均值向量，Σ是所有K类共同的协方差矩阵。**即：假设各类观测对应的x值的均值（p维矩阵）不同，协方差(p*p维)相同。**

- 代入到$\Pr(Y=k\,|X=x)=\frac{\pi_k f_k(x)}{\sum_{l=1}^{K}\pi_l f_l(x)}$，**化简可得，将观测 x 分入**

$$\delta_k(x)=x^T\Sigma^{-1}\mu_k-\frac{1}{2}\mu_k^T\Sigma^{-1}\mu_k+\log(\pi_k)$$

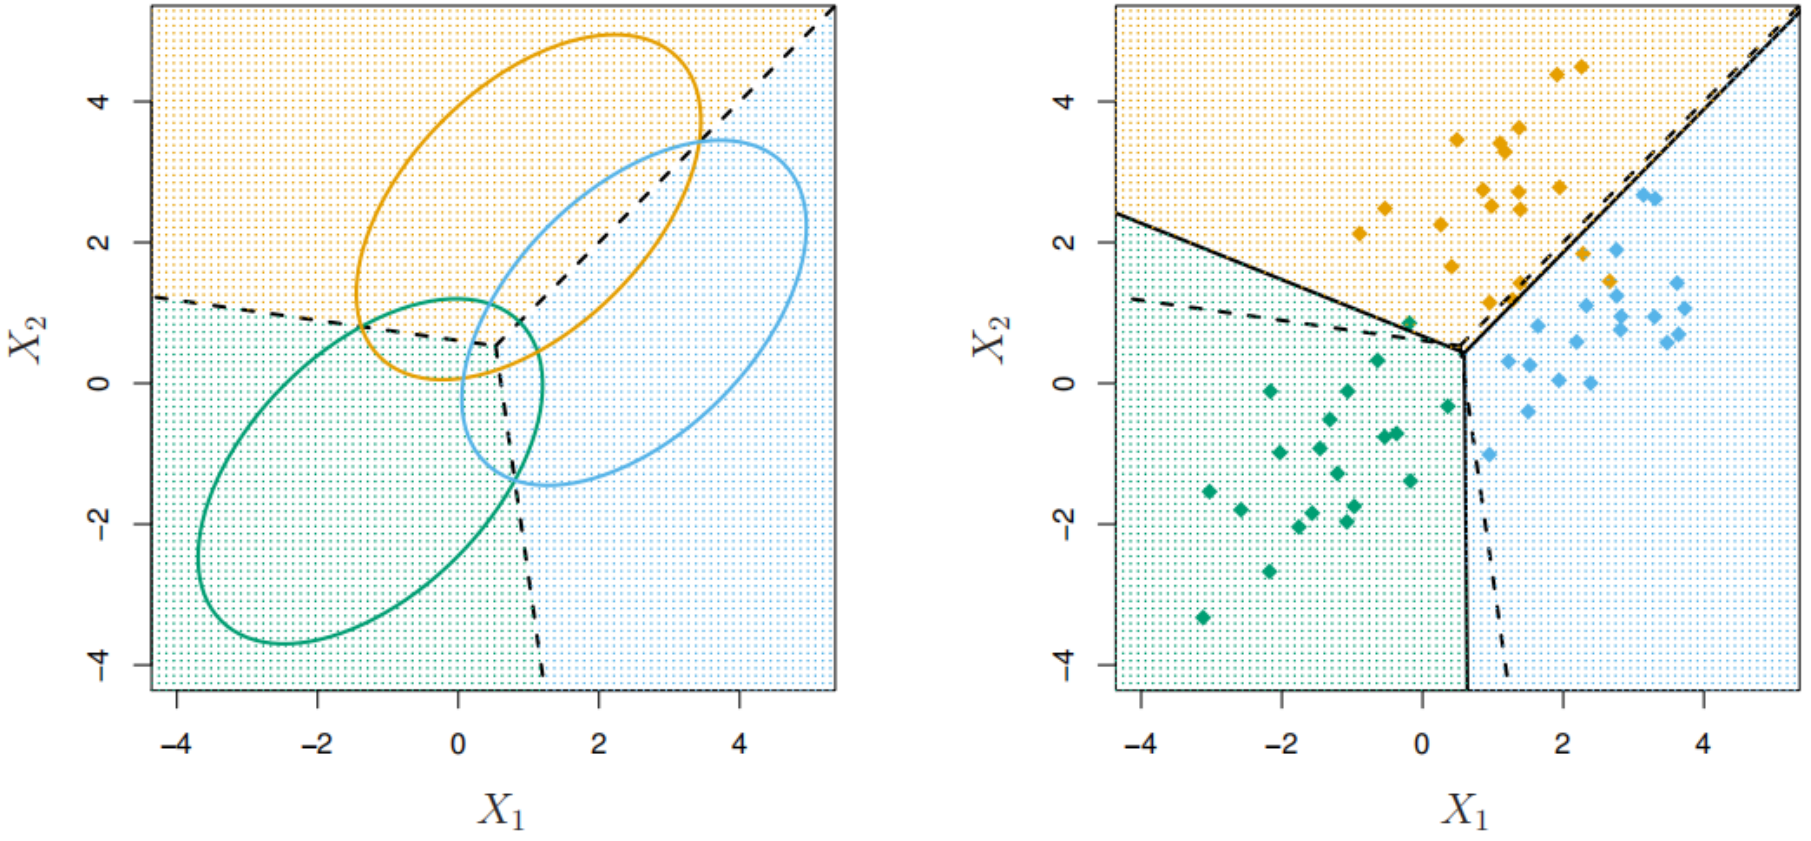
最大的这一类。上式即为判别函数。

进一步展开为：$\delta_k(x)=c_{k0}+c_{k1}x_1+c_{k2}x_2+\cdots+c_{kp}x_p$，**依然是线性函数**。

□相关的参数π_k,μ_k，和∑ **也需要估计**，估计的方法和一维情况类似。

示例：p=2且K=3类

- 下图：三类样本量相同，服从均值不同、协方差矩阵相同的高斯分布，且假设这里$\pi_1 = \pi_2 = \pi_3 = 1/3$
- **虚线**表示贝叶斯决策边界(Bayes decision boundaries)（右侧**实线**为LDA决策边界，估计自各类20个观测样本）





4.4.3（续）LDA的分类应用与性能指标

示例：在Default数据集上应用LDA (p=2, k=2)

		真实违约情况		
		没有	有	共计
预测违约情况	没有	9644	252	9896
	有	23	81	104
	共计	9667	333	10000



分子
分母

将LDA对Default数据10000个训练样本进行拟合（balance和student预测default），**训练错误率为**$(23 + 252)/10000 = 2.75\,\%$。

- 这是**训练错误率**。但因为参数与样本总数n的比值很低（$n = 10000$，$p = 2$），不需要担心过拟合(overfitting)的问题；所以，某种程度上，以此来分析测试错误率；
- **真实情况1**：只有3.33%的人违约，所以即使直接将所有人都归类到不会违约，预测错误率也仅为3.33%；一个普通的零(NULL)分类器也会达到比LDA只高一点的错误率；**所以，不能单纯看错误率；就本例，我们的主要目的是“发现违约者”；**
- **真实情况2**：对于**不会违约**的人，错误率是23/9667=0.2%。但是，在**违约**的333人中，通过LDA后有252/333=75.7%的人漏了，**错误率是75.7%，比较高（漏了）**；

- 虽然综合错误率很低，**但实际作用很受限**，不能辨别高风险的人群（违约概率高的人）；“错误”是一个通用词汇，更多时候，需要结合场景判断当前的系统性能。

示例：在Default数据集上应用LDA (p=2, k=2)

- 我们知道，LDA是在y对应的特征值x呈正态分布的情况下，贝叶斯分类器化简的结果，此时决策边界是线性的，故称线性判别分析LDA；
- 在二分类情况下，隐藏的含义是，把x分到概率>0.5的那一类；

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_k}{\sigma}\right)^2}}{\sum_{l=1}^{K} \pi_l \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_l}{\sigma}\right)^2}}$$

- 对于Default数据集来说，就是把违约概率>0.5的x是为违约，或者说把判别阈值设为0.5；
- 然而，实际上，信用卡公司更关心的是“将违约者判断为未违约”的概率，所以必须要调低违约判别的阈值；

Tips：调整阈值后的新的判别函数，书中没有给出；我们假设为：计算 $p_k(x)$ 后进行分类，侧重于混淆矩阵的理解

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_k}{\sigma}\right)^2}}{\sum_{l=1}^{K} \pi_l \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu_l}{\sigma}\right)^2}}$$

示例：在Default数据集上应用LDA

		真实违约情况		
		没有	有	共计
预测违约情况	没有	9432	138	9570
	有	235	195	430
	共计	9667	333	10000

- **将阈值设定为0.2后**，333个人真实违约者中有138人没有预测正确（阈值0.5时是252），漏掉了138/333=41.4%。对比阈值0.5，改进了识别违约人群的错误率（阈值0.5时：252/333=75.7%）；
- 但现在有235个未违约者被错误地分类了（阈值0.5时是23），因此总错误率略微地增长至(138+235)/10000=3.73%（阈值0.5时是2.75%）（**增长了0.98%，即212=235-23个“未违约者判为违约”的新增错误，以及114=252-138的新发现“违约者”的减少错误**）

对信用卡公司，总错误率的增长当作是更精确地判断真实违约者的**的代价**。

（宁可错杀一千，不可放过一个）



示例：在Default数据集上应用LDA

- **假阳性率(False positive rate)**：将阴性(negative)样本分类成为阳(positive)性样本的比例（分母是全部阴性样本）——前例子中的0.2%=23/9667 （第一类错误）
- **假阴性率(False negative rate)**：将阳性样本分类成阴性样本的比例（分母是全部阳性样本）——前例子中的75.7%=252/333（本例中所关注的“漏网率”；其对应面是： 1- “漏网”=“检出”）



分子
分母

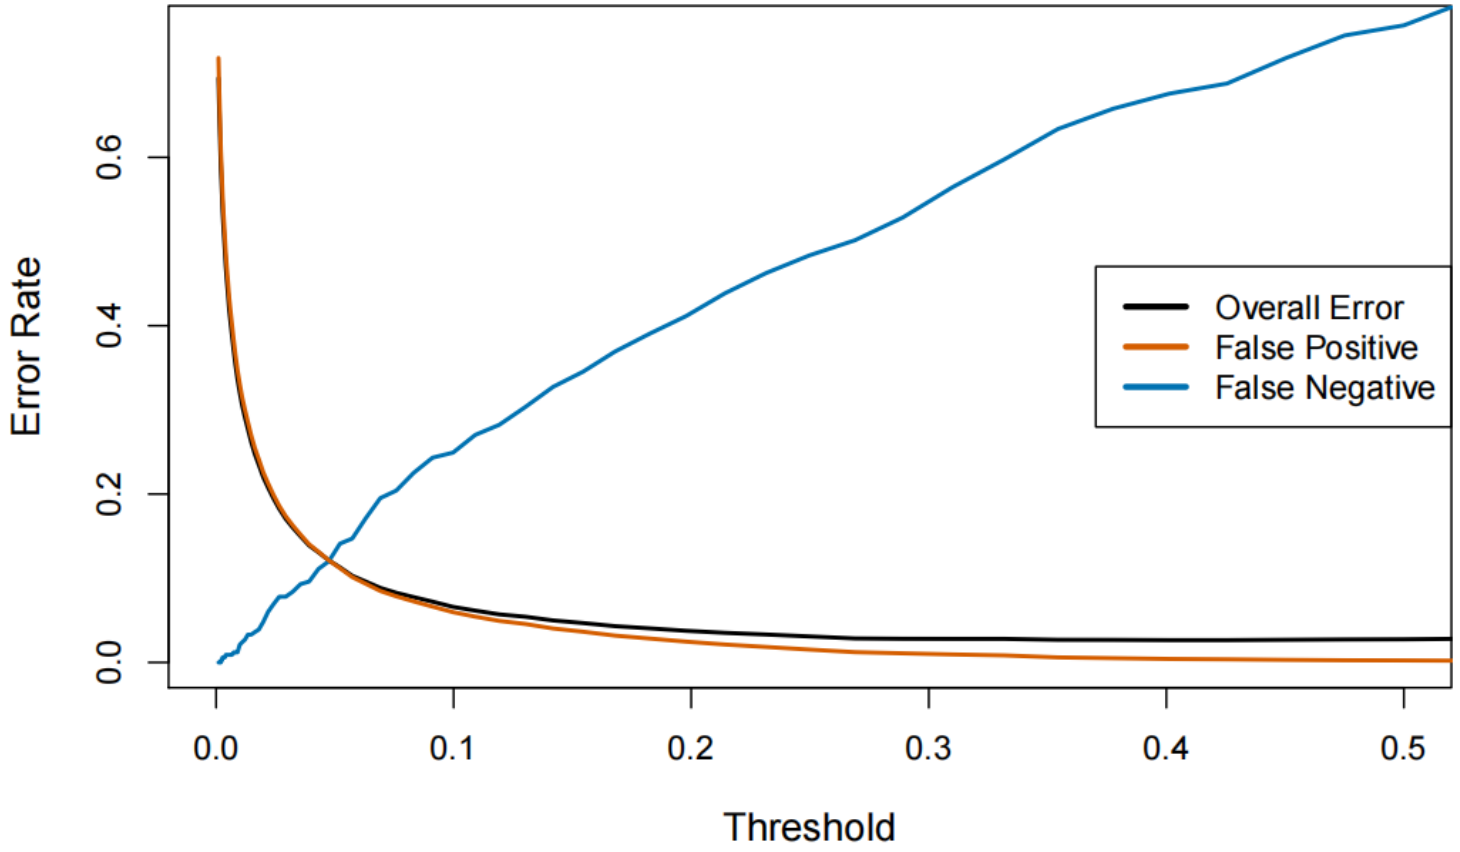
- 在示例1中，分类到会违约(Yes)的标准是

$$\widehat{\Pr}(\text{Default} = \text{Yes} \mid \text{Balance}, \text{Student}) \geq 0.5$$

- 可以通过修改阈值(threshold)从0.5到[0, 1]间其它数值来改变两类错误率，即

$$\widehat{\Pr}(\text{Default} = \text{Yes} \mid \text{Balance}, \text{Student}) \geq threshold$$

示例：在Default数据集上应用LDA



- 阈值0.5时总错误率最低，但违约者的错误率（假阴性率）却比较高（蓝色线）；
- 当阈值下降时，违约者的错误率平稳减少，但是不违约者的错误率（假阳性率）却是增加的。
- 最优阈值根据领域知识确定，如违约成本

错误类型-评价指标（总结）

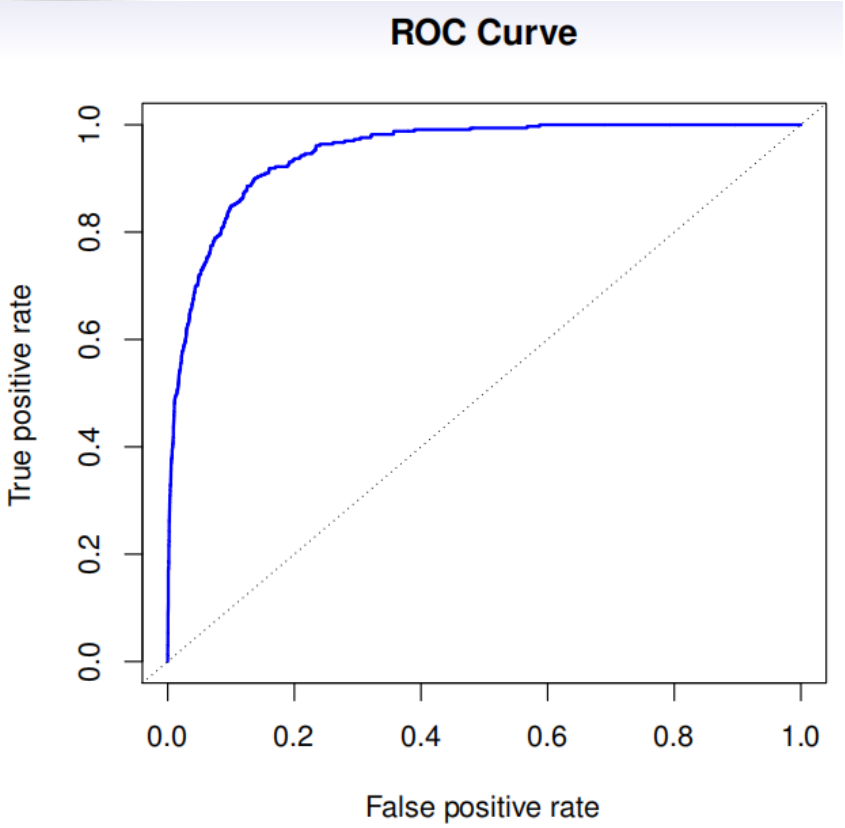
		预测分类		
		0	1	总计
真实分类	0	真阴性值TN	假阳性值FP	N=TN+FP
	1	假阴性值FN	真阳性值TP	P=FN+TP
	总计	N*=TN+FN	P*=TP+FP	

		PREDICTED CLASS	
		Class=Yes	Class=No
ACTUAL CLASS	Class=Yes	a (TP)	b (FN)
	Class=No	c (FP)	d (TN)

名称	定义	同义词
假阳性率	FP/N	第I类错误，数值上：1-特异度
假阴性率	FN/P	第II类错误
真阳性率	TP/P	数值上=1-第II类错误，势，灵敏度(Sensitivity)，召回率（Recall），检出率
预测阳性率	TP/P*	精确度（Precision）
预测阴性率	TN/N*	
真阴性率	TN/N	特异度(Specificity)
错误发现率	FP/P*	

- **对于阴阳的定义**：一般我们关注的事情为阳性，比如“有病”、“是垃圾邮件”、“用户违约”
- 不同的分类器阈值会改变真阳性率和假阳性率，也分别称为灵敏度和1-特异度。
- **分子分母**：率=某一个子集/该子集对应的总体；
- **真假阴阳**：阴阳是预测的阴阳，真假是结果的真假

错误类型-评价指标（总结）



横坐标为false positive rate（FPR）：**FP/(N)；假阳性率**，即实际好人，但根据筛检被判为违约的百分比。（**误判**）

纵坐标为true positive rate（TPR）：**TP/(P);真阳性率**，即实际违约，但根据筛检被判为违约的百分比。（**检出=1-漏网**）

可见：**分母分别为真值（非预测的）的阴性总数和阳性总数**；

(0, 1)点：没有阴性被误判，且阳性全部检出，完美的分类器

(1, 0)点：全部误判，没有检出，最糟糕的分类器

(0, 0)点：没有误判，没有检出，全部判断为0的分类器

(1, 1)点：全部误判，全部检出，全部判断为1的分类器

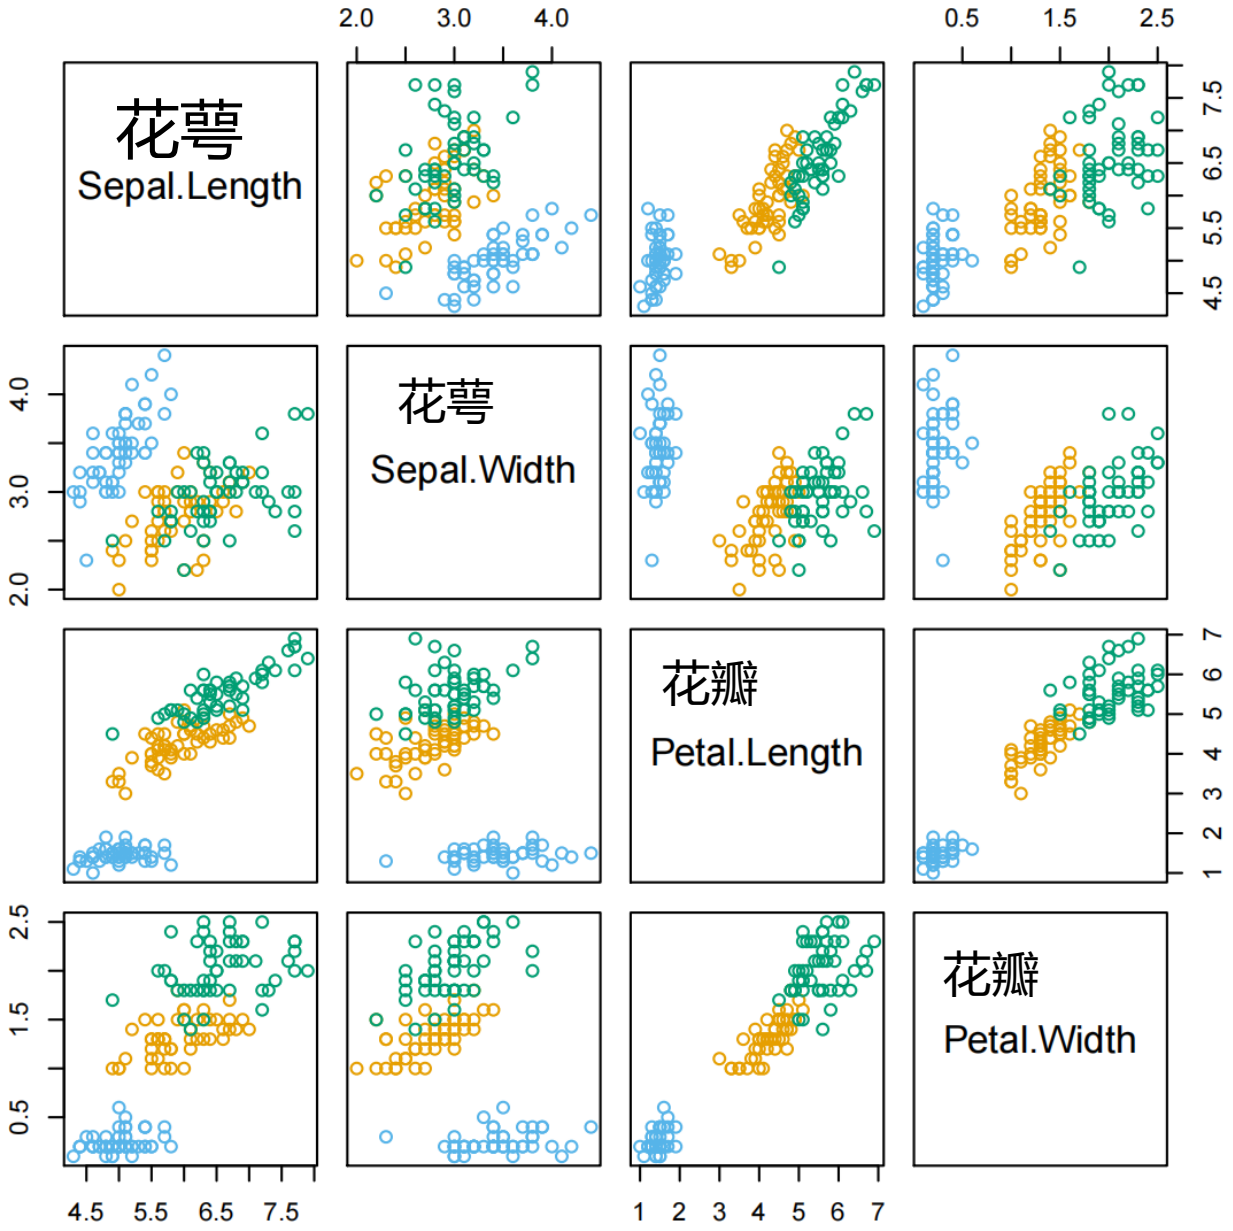
结论：越接近**左上角**，越好；具体的，AUC越大越好

- **ROC曲线**是常用的指标曲线，它可以同时展示出所有可能阈值出现的两类错误。真阳性率：给定阈值下，违约者被正确判断的比例；假阳性率：同样阈值下，未违约者被错误判断的比例。**ROC(Receiver Operating Characteristic**，接收者操作特征曲线)
- 具体的：分类器的表现是通过**ROC曲线下面的面积(area under the ROC curve, AUC)**来表示的。AUC越大，分类器越好。

鸢(Yuan)尾花(Fisher's Iris)数据集（自学）

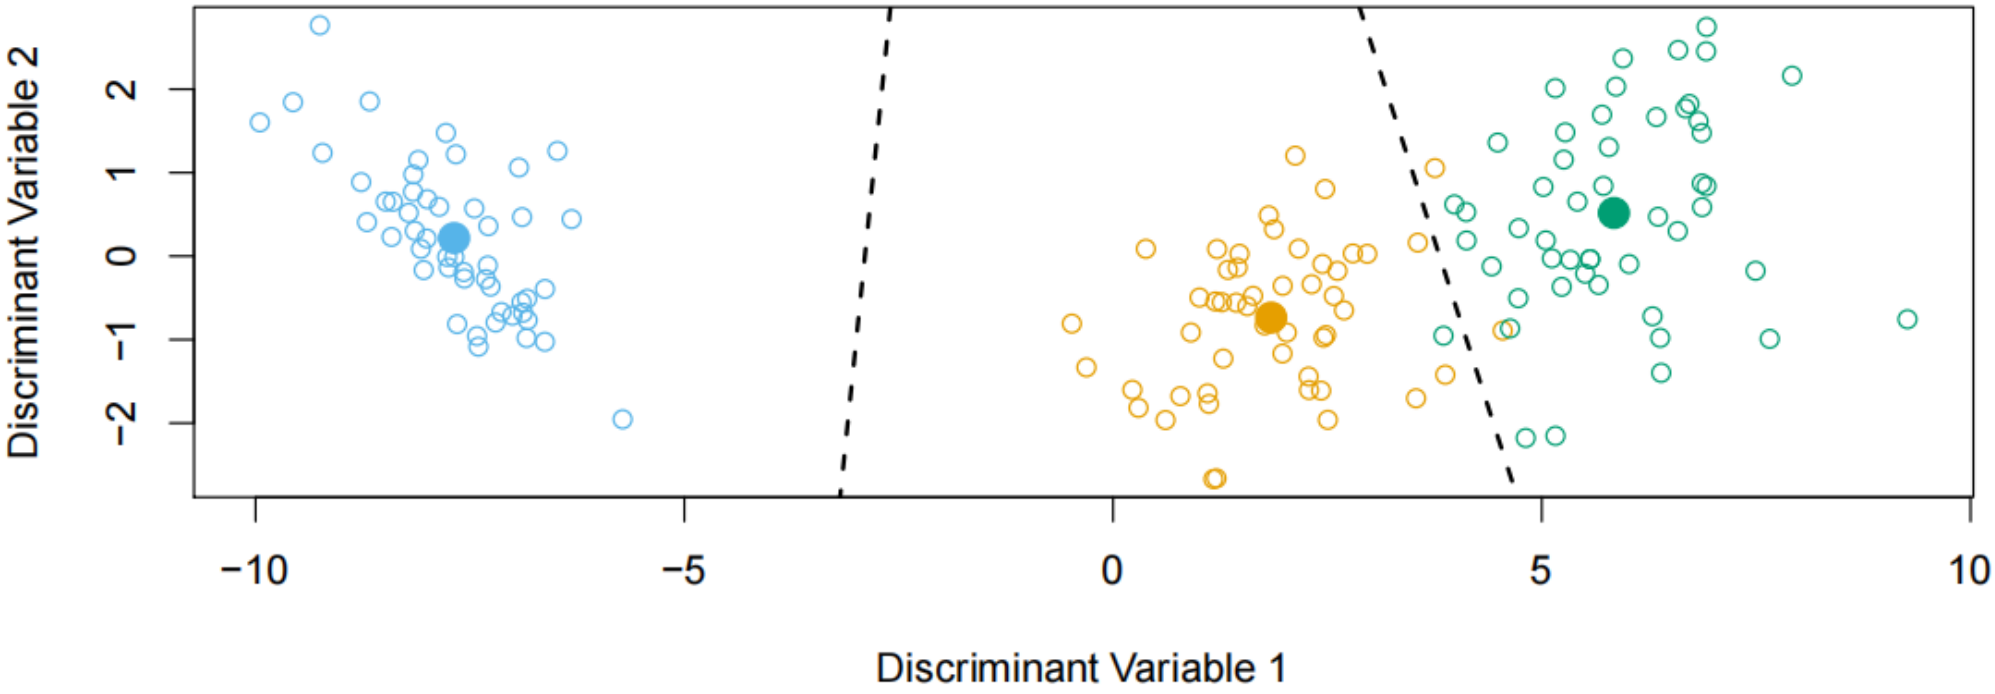
- 4个变量
- 3类（品种）
  - Setosa（山鸢尾）
  - Versicolor（蓝旗鸢尾）
  - Virginic（维吉尼亚鸢尾）
- 50个样本/类
- 线性判别分析LDA正确的分类了150个训练样本中的147个





《鸢尾花》被称为梵高在“圣雷米时期最伟大的作品之一”

鸢尾花(Fisher 's Iris)数据集 （自学）



- 当有K个类别时，可以在$K-1$维图中精确地查看线性判别分析结果。
- 本质上，模型跨越$K-1$维平面，将数据分类到最近的质心(centroid)。
- 即使$K>3$，也可以找到用于可视化判别规则的“最佳”二维平面。

鸢尾花(Fisher 's Iris)数据集（自学）

- 当获得$\delta_k(x)$后，可以进而评估数据属于每个类别的概率

$$\widehat{\Pr}(Y = k \,|X = x) = \frac{e^{\hat{\delta}_k(x)}}{\sum_{l=1}^{K} e^{\hat{\delta}_l(x)}}$$

- 因此分类到$\delta_k(x)$取值最大的类等同于分类到$\widehat{\Pr}(Y = k \,|X = x)$取值最大的类
- 当$K = 2$，如果$\widehat{\Pr}(Y = 2 \,|X = x) \geq 0.5$，则分类到类别2，否则分类到类别1。



4.4.4 二次判别分析（QDA）

二次判别分析（QDA）

后验概率公式：$\Pr(Y=k\,|X=x)=\frac{\pi_k f_k(x)}{\sum_{l=1}^{K}\pi_l f_l(x)}$

- LDA假设每一类观的$f_k(x)$测服从一个多元高斯分布，其中**协方差矩阵Σ_k对所有的K类是相同的**。
- $f_k(x)$还可以假设其它形式
  - 如果假设服从多元高斯分布，**但每一类观测都有自己的协方差矩阵**，则称作**二次判别分析**(quadratic discriminant analysis, QDA)
- 把π_k, μ_k , $\sum_k$的估计代入上式并化简可得：

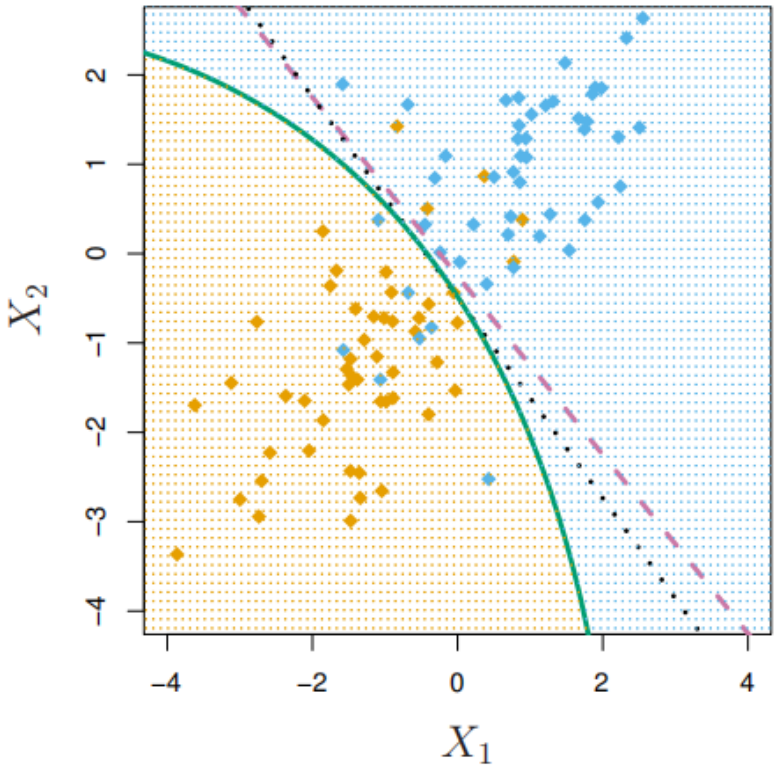
$$\delta_k(x)=-\frac{1}{2}(x-\mu_k)^{\mathrm{T}}\sum_{k}^{-1}(x-\mu_k)+\log\pi_k-\frac{1}{2}\log|\Sigma_k|$$

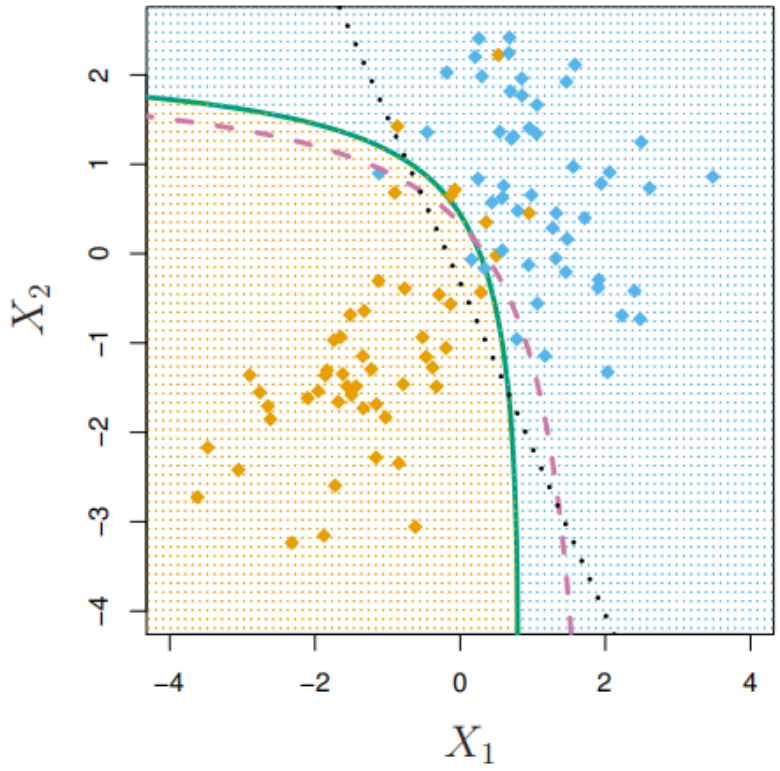
上式是关于x的二次函数，因此叫QDA。

如何选择LDA和QDA?

- 当有p个预测变量，总共有K个类别时，QDA需要预测K个协方差，需要$Kp(p+1)/2$个参数；然而，通过假设K类的协方差矩阵相同，LDA只需要Kp个参数需要估计；
- **LDA没有QDA分类器光滑**，但拥有更低的方差；如果LDA假设的“K类的协方差矩阵相同”是不对的，那么LDA就会有很大的偏差；
- 一般地，如果训练集非常大，倾向于使用QDA，这时，分类器的方差不再是一个主要关心的问题（因为数据量大）；
- 同时，如果训练观测数据量相对较少，LDA比QDA更好决策（QDA要求拟合的数据更多，用少量数据精度不够）

二次判别分析（QDA）





- 左图：真实情况为$\sum_1 = \sum_2$的分类情况，紫线为贝叶斯决策边界、黑色为LDA决策边界、绿色为QDA决策边界；可见，LDA更贴近贝叶斯；
- 右图：真实情况为$\sum_1 \neq \sum_2$的分类情况，紫线为贝叶斯决策边界、黑色为LDA决策边界、绿色为QDA决策边界；可见，QDA更贴近贝叶斯；

R实验：线性判别分析（LDA）

- 现在对Smarket数据做线性判别分析(LDA)。在R中，用MASS库中的lda ()函数拟合一个LDA模型。注意lda()函数与lm()函数语句是相同的，也和glm()类似，除了缺少family选项。现在对2005年以前的观测进行拟合。

```
> library(MASS)
> lda.fit = lda(Direction~Lag1 + Lag2, data = Smarket, subset = train)
> lda.fit
Call:
lda(Direction ~ Lag1 + Lag2, data = Smarket, subset = train)

Prior probabilities of groups:
    Down       Up
0.491984 0.508016

Group means:
            Lag1        Lag2
Down  0.04279022  0.03389409
Up   -0.03954635 -0.03132544

Coefficients of linear discriminants:
            LD1
Lag1 -0.6420190
Lag2 -0.5135293
```

R实验：线性判别分析（LDA）

- predict ()函数返回一个三元列表。第一个元素class存储了LDA关于市场动向的预测。第二个元素posterior是一个矩阵，其中第k列是观测属于第k类的后验概率，通过(4.10)可以计算。最后，x包含着线性判别评分（比如公式4.13或4.19），这在之前描述过。

```
> lda.pred = predict(lda.fit, Smarket.2005)
> names(lda.pred)
[1] "class"     "posterior" "x"
```

- 就像在4.5节所研究的，LDA和逻辑斯谛回归预测结果几乎一样。

```
> lda.class = lda.pred$class
> table(lda.class, Direction.2005)
         Direction.2005
lda.class Down  Up
     Down   35  35
     Up     76 106
> mean(lda.class == Direction.2005)
[1] 0.5595238
```

R实验：线性判别分析（QDA）

- 现在对smarket数据拟合QDA模型。QDA在R中可以调用MASS库中的qda()函数来实现，其语句与lda()一样。

```
> qda.fit= qda(Direction~Lag1 + Lag2, data = Smarket, subset = train)
> qda.fit
Call:
qda(Direction ~ Lag1 + Lag2, data = Smarket, subset = train)

Prior probabilities of groups:
    Down       Up
0.491984 0.508016

Group means:
            Lag1        Lag2
Down  0.04279022  0.03389409
Up   -0.03954635 -0.03132544
```

R实验：线性判别分析（QDA）

- 输出包含类平均值，但是**不包含线性判别系数**，因为QDA分类器是一个二次函数，不是预测变量的线性函数。predict ()函数与LDA执行方式完全一样。

```
> qda.class = predict(qda.fit, Smarket.2005)$class
> table(qda.class, Direction.2005)
         Direction.2005
qda.class Down  Up
     Down   30  20
     Up     81 121
> mean(qda.class == Direction.2005)
[1] 0.5992063
```

- 有趣的是，即使没有用2005年的数据来拟合模型，在几乎60%的时间里QDA预测也都是准确的。这个准确性水平对难以精准建模的股票市场数据面言令人兴奋不已。**这表明QDA所假设的二次型比LDA和逻辑斯谛回归的线性假设更接近真实的关系**。然而，在确信这种方法会始终战胜市场之前，还是建议在个大的测试集上评估这种方法的表现。

4. 方法比较

逻辑斯谛回归与LDA比较

- **逻辑斯谛回归和LDA**是紧密相连的。考虑类别数为2，LDA框架下，得到如下对数形式：

$$log\left(\frac{p_1(x)}{1-p_1(x)}\right) = \log\left(\frac{p_1(x)}{p_2(x)}\right) = c_0 + c_1x_1 + \cdots + c_px_p$$

它与逻辑斯谛回归有相同的形式，两者只是在拟合（参数估计）过程中有一些差异

  - 逻辑斯谛回归中参数是由**极大似然估计**出来的
  - LDA是基于后验概率的分类，具体的概率值通过**估计的正态分布均值和方差**计算出来的
  - 两者得到的结果应该是接近的。但LDA假设观测服从每一类协方都相同的高斯分布，当假设成立时，LDA能提供更好的结果

- **逻辑斯谛回归**也可以用于拟合类似于**QDA**的二次的决策边界，方法是在模型中显示的**增加二次项**

- 逻辑斯谛回归是解决分类任务的常见方法，特别当$K = 2$时。
- 当$K > 2$时，LDA也比较有用。
- LDA在 n 较小（样本较少）或类差别明显且满足高斯假设时，很有用。

本周作业（第五周）

教材4.7习题1、2、4、5、6、8、9、10、11、12

