



近五年美国股票市场结构动态变化分析

基于滚动相关距离、MDS、聚类与简单预测的实证研究

MarketManifold 展示支持

近五年美国股票市场结构动态变化分析

基于滚动相关距离、MDS、聚类与探索性预测的实证研究

汇报人：陶圣叶

学号：2025221047

课程：数据挖掘

用途：项目理解、逐页讲稿、答辩准备与现场速查



目录

1 使用方法与展示总策略	2
1.1 一句话版本	2
1.2 三层结论边界	2
1.3 时间安排	2
2 项目整体理解	4
2.1 我们究竟研究了什么	4
2.2 数据与样本	4
2.3 90 日窗口到底是什么意思	4
2.4 完整方法链条	4
2.5 关键概念的通俗与正式解释	5
2.5.1 对数收益率	5
2.5.2 相关矩阵	5
2.5.3 相关距离	5
2.5.4 MDS	5
2.5.5 聚类	5
2.5.6 Procrustes 对齐	6
2.5.7 平均相关性与 PC1 解释率	6
2.5.8 ARI、NMI 与轮廓系数	6
2.6 三个最重要的实证发现	6
2.6.1 发现一：市场压力上升时，结构趋于集中	6
2.6.2 发现二：最新窗口比 2022 年压力阶段更分散	6
2.6.3 发现三：动态群组不等于静态行业	7
2.7 预测实验到底说明了什么	7
2.8 它算不算量化研究	7
3 逐页演讲稿	8
4 答辩问题与标准回答	12
5 现场表达禁区	13
6 一页速查卡	15
7 排练、时间控制与故障预案	17
7.1 上台前 30 分钟检查	17
7.2 两轮排练法	17
7.3 超时处理	17
7.4 GIF 故障	17
7.5 突然忘词	17
7.6 老师提出无法立即回答的问题	18
8 展示前最后判断	18



1 使用方法与展示总策略

这份材料不是用来从头到尾逐字背诵的，而是分成三个层次使用：

1. **先理解**：阅读第 2 节，能够不用 PPT 解释项目的逻辑。
2. **再练习**：按照第 3 节逐页讲两遍，形成稳定的语言节奏。
3. **上台前速查**：只看第 6 节的一页式提纲和关键数字。

展示原则

本次展示的目标不是证明你掌握了所有金融计量方法，而是清楚地说明：

1. 我们提出了什么问题；
2. 如何把价格数据转化成可观察的市场结构；
3. 数据给出了哪些证据；
4. 哪些结论可以说，哪些结论不能说。

1.1 一句话版本

我们把股票市场看成一个随时间变化的关系网络，而不是一组彼此独立的价格序列。对每个 90 个交易日窗口，我们计算股票收益率之间的相关关系，将其转换为距离，再通过 MDS 和聚类得到二维市场结构图。结果显示，高波动时期股票之间的共同运动会明显增强，市场结构更集中；稳定时期则更加分散。聚类具有时间连续性，但并不等同于传统行业分类。最后，我们做了一个探索性的下一窗口波动率预测实验，但只把它视为统计验证，不解释为可交易策略。

1.2 三层结论边界

层次	可以说	不要说
数据直接支持	高波动、高相关、较高 PC1 解释率在样本内高度同步；最新窗口较分散。	“相关性上升必然导致市场下跌”或“已经证明因果关系”。
数据基本支持	聚类在相邻窗口间具有连续性；行业标签只能部分解释动态聚类。	“市场天然存在 6 个固定类别”或“聚类完全超越行业分类”。
探索性证据	包含当前波动率与结构指标的特征组合对下一窗口波动率表现出一定预测拟合。	“结构指标已经形成稳定交易信号”或“模型可以赚钱”。

1.3 时间安排

默认按 9 分钟设计：



页码	内容	建议时间
1	开场与项目定位	30 秒
2	研究动机与三个问题	55 秒
3	数据集与实验设计	55 秒
4	整体技术路线	50 秒
5	关键方法解释	65 秒
6	动态 GIF	65 秒
7	三个指标同步变化	60 秒
8	三个关键窗口比较	60 秒
9	聚类稳定性与行业解释	60 秒
10	探索性预测	55 秒
11	结论与研究边界	45 秒
合计		约 9 分钟

如果只有 6 分钟，第 4、5 页各压缩至 30 秒，第 8 页只讲最新窗口，第 10 页只讲“探索性验证与局限”。如果有 12 分钟，可以增加关键概念解释和答辩式补充。



2 项目整体理解

2.1 我们究竟研究了什么

传统市场分析经常关注某个指数涨跌、某只股票收益或单一波动率。但市场不是一组独立的股票，而是一个关系系统。市场压力增大时，原本不同的股票可能开始同步涨跌；稳定时期，行业和个股差异又会重新出现。

因此，我们研究的对象不是某只股票的绝对价格，而是：

核心研究对象

股票之间的收益率关系如何随时间改变。

对每一个滚动窗口，都可以得到一张“市场快照”。连续的快照连接起来，就是市场结构演化。

2.2 数据与样本

本项目使用 46 只美国大市值股票，覆盖 11 个核心行业，样本时间约为 2021 年 6 月至 2026 年 6 月，共 1255 个共同交易日。正式统计分析采用：

- 90 个交易日滚动窗口；
- 10 个交易日步长；
- 共形成 117 个分析窗口；
- GIF 为了视觉连续性，保持 90 日窗口，但改为 1 个交易日步长。

数据来源的安全表述

原始数据来自本地美国股票日频历史行情归档，文件结构与 Stooq 常见格式一致，但具体来源和复权状态未被独立核验。展示中不需要主动展开；若老师追问，应如实说明。

2.3 90 日窗口到底是什么意思

90 日窗口不是只研究 90 天，也不是 GIF 只播放 90 天。它的含义是：

- 每一帧或每一个分析点，都使用截至该日期之前最近 90 个交易日；
- 窗口不断向前滚动，因此可以覆盖整个约 5 年样本；
- 正式统计每次向前移动 10 个交易日；
- GIF 每次向前移动 1 个交易日，使画面更连续。

可以把它理解为一个长度固定的观察镜头：镜头长度是 90 日，但镜头从 2021 年一路移动到 2026 年。

2.4 完整方法链条

1. 获取并清洗价格数据，统一交易日和股票代码；
2. 将价格转换为对数收益率；
3. 在每个 90 日窗口中计算股票收益率相关矩阵；

4. 把相关性转换成几何距离；
5. 用 MDS 将高维距离结构压缩到二维；
6. 用聚类识别具有相似市场行为的股票群组；
7. 用 Procrustes 对齐相邻窗口，减少任意旋转、镜像和平移；
8. 计算波动率、平均相关性、PC1 解释率、ARI、NMI、轮廓系数等指标；
9. 比较关键窗口，并进行探索性的下一窗口波动率预测。

2.5 关键概念的通俗与正式解释

2.5.1 对数收益率

$$r_{i,t} = \log P_{i,t} - \log P_{i,t-1}.$$

通俗解释：把价格变化转成可比较的日收益变化。股票价格水平不同，但收益率可以放在一起比较。

正式解释：对数收益率具有时间可加性，在日频小幅变化下接近普通收益率，是金融时间序列分析的常见输入。

2.5.2 相关矩阵

对 46 只股票，每个窗口得到一个 46×46 的相关矩阵。

通俗解释：它描述任意两只股票在最近 90 个交易日里是否倾向于一起涨跌。

正式解释：矩阵元素 ρ_{ij} 是股票 i 与股票 j 的 Pearson 收益率相关系数。

2.5.3 相关距离

$$d(i, j) = \sqrt{2(1 - \rho_{ij})}.$$

通俗解释：相关性越高，距离越近；相关性越低，距离越远。这样就能把抽象的相关关系转成可以画图的几何关系。

边界：距离代表收益率联动程度，不代表公司地理距离、估值差异或基本面距离。

2.5.4 MDS

通俗解释：MDS 尽量保留股票之间的相对距离，把高维关系压缩到二维平面，得到一张“市场地图”。

正式解释：多维尺度分析寻找二维坐标，使二维欧氏距离尽可能逼近原始相关距离。二维坐标轴本身没有固定经济含义，主要看点与点之间的相对距离和群组结构。

2.5.5 聚类

通俗解释：把近期市场行为相似的股票归入同一组，颜色用于区分这些数据驱动的群组。

边界：颜色编号没有固定语义，不能直接把“第 1 类”解释为科技股或金融股。聚类是对连续结构的近似切分。

2.5.6 Procrustes 对齐

通俗解释：MDS 每次单独计算时，整张图可能任意旋转、翻转或平移。Procrustes 把相邻窗口摆到尽量一致的方向，使动画里的移动更接近真实结构变化，而不是坐标系跳动。

注意：它只修正方向、镜像和平移，不应人为改变股票之间的相对距离尺度。

2.5.7 平均相关性与 PC1 解释率

平均相关性：所有股票两两相关系数的平均值，描述市场整体共同运动强度。

PC1 解释率：第一主成分解释全部收益波动的比例。数值越高，越多股票变化可以被一个共同因子解释。

二者本身刻画的是相近现象，因此相关系数达到 0.993 并不神秘，也不能视为两个完全独立的发现。

2.5.8 ARI、NMI 与轮廓系数

- **相邻窗口 ARI：**相邻两个窗口的聚类成员是否相似。均值 0.741，说明具有明显连续性。
- **行业-聚类 ARI：**动态聚类与传统行业分类的一致程度。均值 0.163，说明不能简单等同。
- **行业-聚类 NMI：**行业标签能解释多少聚类信息。均值 0.461，说明有一定解释力，但不充分。
- **轮廓系数：**聚类内部紧密、不同簇之间分离的程度。均值 0.109，说明横截面边界较模糊。

正确解读轮廓系数 0.109

这不等于“项目失败”。它更可能说明股票位于连续的风险因子空间中，市场结构不是 6 个边界清晰、长期固定的盒子。聚类是一种便于观察和解释的近似划分。

2.6 三个最重要的实证发现

2.6.1 发现一：市场压力上升时，结构趋于集中

样本中平均相关性、等权市场波动率和 PC1 解释率高度同步：

- 平均相关性与市场波动率：0.959；
- 平均相关性与 PC1 解释率：0.993；
- 市场波动率与 PC1 解释率：0.978。

含义是：市场波动加剧时，个股更容易被共同市场因子驱动，股票之间的独立性下降。

2.6.2 发现二：最新窗口比 2022 年压力阶段更分散

关键窗口结果：

窗口	日期	平均相关性	市场波动率	PC1 解释率
最高波动窗口	2022-08-30	0.510	0.261	0.538
最高相关窗口	2022-12-22	0.543	0.243	0.564
最新窗口	2026-06-15	0.105	0.116	0.213

最新窗口二维平均距离约为 1.159，明显高于压力窗口，说明股票间的收益率联动减弱、横截面差异扩大。

2.6.3 发现三：动态群组不等于静态行业

相邻窗口 ARI 较高，而行业-聚类 ARI 较低，说明聚类并非随机跳动，但也不是对 GICS 行业分类的简单复制。市场中的实际联动可能同时受到利率敏感性、成长/价值风格、共同资金持仓、风险偏好和宏观冲击等因素影响。

2.7 预测实验到底说明了什么

预测目标是下一窗口的等权市场年化波动率。模型结果为：

模型	MAE	RMSE	R^2
naive last train	0.0353	0.0535	-0.233
LinearRegression	0.0185	0.0289	0.640
RandomForestRegressor	0.0198	0.0306	0.598

正确结论是：

预测实验的安全表述

包含当前市场波动率与市场结构指标的特征组合，在当前样本和弱基线下表现出一定的短期统计延续性。由于窗口高度重叠、样本规模有限、基线不够强且缺乏外部验证，不能把结果解释为稳定预测能力或可交易策略。

2.8 它算不算量化研究

算。它属于量化市场结构分析、市场状态识别和风险监控的入门研究原型。它已经完成数据、特征、模型、验证和解释闭环，但还不是完整量化交易策略，因为尚未建立明确的交易规则、仓位管理、交易成本模型、滚动回测和跨市场样本外验证。

3 逐页演讲稿

第 1 页：封面

本页任务：在 30 秒内说清项目名称、研究对象和主线。

大家好，我是陶圣叶。今天汇报的数据挖掘课程项目叫 MarketManifold，中文题目是“近五年美国股票市场结构动态变化分析”。

这个项目不直接预测某一只股票的价格，而是把股票市场看成一个随时间变化的关系网络。我们重点研究股票收益率之间的相关结构，观察市场什么时候趋于集中、什么时候趋于分散，以及这些结构指标是否包含有限的短期预测信息。

过渡句：首先，我想说明为什么市场结构本身值得研究。

第 2 页：为什么研究“市场结构”

本页任务：提出动机和三个问题，不要读满页面。

股票市场不是 46 条彼此独立的价格曲线。市场在高压阶段，资金可能同时撤离多个资产，股票之间的联动会增强；而在稳定阶段，行业和个股差异会重新显现。

因此，我们关注三个问题。第一，市场波动加剧时，股票之间是否会更加集中地共同运动；第二，数据驱动的聚类是否只是传统行业分类的复制；第三，这些结构指标是否包含下一阶段波动率的统计信息。

后面的实验就是围绕这三个问题展开。

视觉指引：从左到右指向三个研究问题，不要逐字读下方说明。

过渡句：为了回答这些问题，我们先构建统一、可比较的滚动窗口数据集。

第 3 页：数据集与实验设计

本页任务：建立可信度，讲清“46、1255、90、10、117”五个数字。

我们筛选了 46 只美国大市值股票，覆盖 11 个核心行业。样本从 2021 年 6 月延伸到 2026 年 6 月，共有 1255 个共同交易日。

数据先统一日期、股票代码和价格字段，再转成对数收益率，并对极端收益进行缩尾处理。正式分析使用 90 个交易日窗口、10 个交易日步长，共形成 117 个窗口。划分和预测都按时间顺序进行，避免把未来信息随机混入训练阶段。

需要说明的是，原始数据是本地美国股票日频行情归档，格式与 Stooq 常见结构一致，但具体来源和复权状态没有独立核验，所以这也是研究局限之一。

过渡句：接下来，我们把原始价格一步步转换成动态市场地图。

第 4 页：从价格序列到动态市场地图

本页任务：讲清整体流水线，不深入公式。

整个流程可以概括为十步。我们从原始价格出发，完成数据对齐和对数收益率计算；在每个 90 日窗口中得到股票相关矩阵，再把相关性转换为距离。

随后使用 MDS 把高维距离结构压缩到二维，并进行聚类。由于每个窗口的二维坐标方向可能任意变化，我们再用 Procrustes 方法对齐相邻窗口。最后计算平均相关性、波动率、PC1 解释率、聚类稳定性等指标。

对照方法使用 PCA 和 KMeans，主要用于检验结论是否完全依赖某一种表示方式。

过渡句：其中最关键的三步，是相关距离、MDS 表示和动态对齐。

第 5 页：相关距离、MDS 与动态对齐

本页任务：让非技术听众理解公式的含义。

首先，我们将价格转成对数收益率，避免不同股票价格水平不可比。

然后，把相关系数转换成相关距离。两只股票相关性越高，距离越近；相关性越低，距离越远。这样，抽象的相关矩阵就可以转换成几何结构。

MDS 的作用，是尽量保留这些相对距离，把 46 只股票压缩到二维平面。需要强调的是，横轴和纵轴没有固定经济含义，我们主要观察点与点之间的距离。

最后，Procrustes 对齐用于消除不同窗口之间任意旋转、镜像和平移造成的视觉跳动，让动画更能反映结构本身的变化。

不要说：“MDS 精确还原了全部高维信息。”二维表示一定存在信息损失。

过渡句：有了这套表示之后，我们就能连续观察整个样本期内的市场结构演化。

第 6 页：市场结构如何随时间演化

本页任务：引导观众看 GIF，而不是解释每一只股票。

这一页展示的是整个样本期的动态市场地图。每一帧都使用截至当前日期之前最近 90 个交易日，动画则按交易日向前推进，所以覆盖的是整个近五年样本，而不是只展示 90 天。

观看时可以关注三件事。第一，点云是在收缩还是分散；第二，颜色群组是否发生重组；第三，波动较大的股票点是否明显变大。

当市场压力上升时，很多股票会向同一区域收缩，表示收益率联动增强；在较稳定时期，点云会重新拉开，个股和板块差异更加明显。

视觉指引：先指日期，再指点云整体，最后指右侧四个说明框。不要追着动画逐点讲。

GIF 不播放时的替代句：

这里的静态图是某一窗口的预览。即使动画无法播放，后面三个代表性窗口的对比仍能清楚显示集中和分散状态的差异。

过渡句：这种视觉变化，在三个量化指标上也表现得非常明显。

第 7 页：相关性、波动率与共同因子高度同步

本页任务：讲清三条曲线是同一结构现象的不同刻画。

左侧依次是平均相关性、市场年化波动率和 PC1 解释率。可以看到，三条曲线在关键阶段高度同步。

平均相关性与波动率的相关系数是 0.959；平均相关性与 PC1 解释率是 0.993；波动率与 PC1 解释率是 0.978。

这说明市场压力增大时，股票之间的共同运动会增强，更多收益变化被单一共同因子解释。但平均相关性和 PC1 本身刻画的是相近现象，因此 0.993 不能被包装成两个完全独立的发现。

另外，相邻窗口共享 80 个交易日，所以这些系数用于描述样本内同步关系，不直接等于独立样本下的严格统计显著性。

过渡句：为了让这种变化更直观，我们比较三个具有代表性的窗口。

第 8 页：高波动、高相关与最新市场结构

本页任务：用三图对比形成全场最直观的结论。

左图是最高波动窗口，结束于 2022 年 8 月 30 日，市场年化波动率为 0.261，平均相关性为 0.510。中图是最高相关窗口，结束于 2022 年 12 月 22 日，平均相关性达到 0.543，PC1 解释率为 0.564。

右图是最新窗口，平均相关性下降到 0.105，PC1 解释率下降到 0.213，二维平均距离上升到约 1.159。可以看到，股票分布明显更加分散。

因此，相比 2022 年的压力阶段，最新窗口不是典型的全市场同步收缩状态，而是呈现更明显的横截面分化。这里的“分散”不代表市场一定上涨或绝对安全，只表示共同市场因子的控制力较弱。

过渡句：接下来再看这些群组是否稳定，以及它们与传统行业分类是什么关系。

第 9 页：聚类具有连续性，但横截面分离度有限

本页任务：主动解释看似矛盾的四个数字。

相邻窗口 ARI 的均值是 0.741，说明聚类在时间上具有较强连续性，并不是每个窗口都随机重排。

但聚类与行业分类的 ARI 只有 0.163，NMI 为 0.461。这说明行业标签能够解释一部分市场联动，但不能完全决定动态群组。

同时，平均轮廓系数只有 0.109，说明不同簇之间的边界并不清晰。因此，更准确的解释不是“市场天然存在六个固定类别”，而是股票分布在一个连续的风险因子空间里，聚类只是为了观察和解释而进行的近似划分。

过渡句：最后，我们做了一个简单的预测实验，检验这些指标是否包含下一窗口的信息。

第 10 页：结构指标能否预测下一窗口波动率

本页任务：展示结果，但主动收紧结论。

预测目标是下一窗口的等权市场年化波动率。在线性回归和随机森林中，线性回归取得了最低的 MAE 和 RMSE，测试集 R^2 为 0.640；随机森林的 R^2 为 0.598，都优于当前使用的常数基线。

不过，这个结果必须谨慎解释。第一，输入特征中包含当前市场波动率，因此不能把全部预测表现归因于结构指标；第二，相邻窗口高度重叠，有效独立样本少于 117；第三，当前基线较弱，也没有完成跨市场或多阶段外部验证。

所以，这一页只说明特征组合具有一定的短期统计延续性，不代表已经形成稳定预测能力，更不代表可交易策略。

老师追问基线时：

更严格的下一步应该加入持久性基线，也就是直接用当前窗口波动率预测下一窗口，并比较“仅波动率”“仅结构指标”和“波动率加结构指标”三组模型，才能检验结构变量是否提供增量信息。

过渡句：最后，我对主要发现和研究边界做一个总结。

第 11 页：结论与研究边界

本页任务：用三个发现和一句 takeaway 收束。

本项目有三点主要发现。

第一，市场结构具有明显动态性，高波动阶段平均相关性和共同因子解释率上升，结构更加集中。

第二，数据驱动聚类具有时间连续性，但不能被传统行业分类完全解释，说明实际联动受到多种动态因子共同影响。

第三，包含当前波动率与结构指标的特征组合表现出初步的短期统计信息，但预测结果仍然是探索性的。

研究局限包括股票池规模较小、数据来源和复权状态未完全核验、窗口高度重叠、模型和基线较简单，以及尚未建立因果关系。

最后，本项目的核心认识是：市场风险不仅表现为价格波动，也表现为资产关联结构的同步收缩。谢谢大家。

4 答辩问题与标准回答

Q1: 为什么选择 90 个交易日窗口？

90 日约对应一个季度，能够积累足够观测来估计 46 只股票的相关结构，同时又不会像过长窗口那样完全抹平阶段变化。它是稳定性与响应速度之间的折中。更严格的研究应比较 60、90、120 日窗口的稳健性。

Q2: 为什么正式分析用 10 日步长，而 GIF 用 1 日步长？

正式统计使用 10 日步长，减少计算量和相邻样本的重复；GIF 的目标是展示连续演化，因此改为每天推进一帧。两者都保持 90 日窗口，方法含义一致，但 GIF 的逐日帧不用于增加统计独立样本。

Q3: 相邻窗口共享 80 天，会不会导致结果虚高？

会提高序列平滑性和相邻窗口连续性，因此我们不把 117 个窗口当作 117 个完全独立样本。相关系数和相邻 ARI 主要用于样本内结构描述，预测结果也因此只视为探索性证据。

Q4: 为什么只选 46 只股票？

固定股票池可以保证所有窗口在同一资产集合上比较，并使 MDS、聚类和动画能在普通计算机上稳定运行。但它不能代表完整美国市场，也可能存在大市值和幸存者偏差，这是明确局限。

Q5: 为什么不直接看标普 500 指数？

指数只提供整体价格或波动水平，无法告诉我们内部股票是否同步、哪些群组在重组、分散化是否失效。本项目研究的是指数背后的横截面关系结构。

Q6: 平均相关性和 PC1 解释率为什么达到 0.993？

二者都在刻画市场共同运动强度。平均相关性上升时，收益矩阵更接近由一个共同因子主导，第一主成分解释率通常也会上升。因此这个高相关具有结构上的合理性，但不应被当作两个独立证据。

Q7: MDS 的两个轴分别代表什么？

通常没有稳定、直接的经济含义。MDS 的目标是保留点之间的相对距离，而不是构造两个可命名的经济因子。因此只解释距离、聚集和分散，不解释“左边代表科技、上方代表金融”。

Q8: 为什么要做 Procrustes 对齐？

每个窗口单独运行 MDS 时，坐标可以任意旋转、镜像和平移，但这些变化不代表市场结构变化。Procrustes 让相邻窗口尽量保持同一方向，减少动画中的伪跳动，同时保留点间相对距离。

Q9: 轮廓系数 0.109 是否说明聚类失败？

它说明横截面群组边界较弱，不适合宣称存在六个天然、清晰的类别。但相邻 ARI 较高，说明这种近似分组具有时间连续性。更合理的理解是市场结构接近连续谱，聚类用于辅助解释，而不是发现绝对类别。

Q10：聚类与行业分类不一致，是否意味着行业分类没用？

不是。NMI 为 0.461，说明行业具有一定解释力；但 ARI 较低，说明短期收益联动还受到利率敏感性、风险风格、共同持仓和宏观冲击等跨行业因素影响。

Q11：为什么高波动时期相关性往往上升？

在风险厌恶和流动性压力上升时，资金可能同时卖出多类资产，宏观共同因子对个股的影响增强，分散化效果下降。但本项目展示的是样本内同步关系，没有建立严格因果链。

Q12：最新窗口相关性低，是否说明美股安全？

不能。它只说明当前样本中股票收益联动较弱、横截面差异较大。低相关市场仍可能存在估值风险、局部行业风险和个股风险，也不直接决定指数未来涨跌。

Q13：预测实验有没有数据泄漏？

数据按时间顺序划分，没有随机打乱，这是正确方向。但预处理参数是否完全只在训练期估计、窗口高度重叠以及弱基线问题仍需进一步检查。因此我们只把结果作为探索性验证。

Q14：为什么线性回归比随机森林更好？

样本量有限、特征维度不高，而且波动率和结构指标之间可能主要呈现平滑、近似线性的关系。复杂模型在小样本下未必占优，也可能更容易过拟合。

Q15：这个项目能直接用于交易吗？

不能直接用于交易。目前更适合市场状态识别和组合风险监控。形成交易策略还需要明确的信号规则、持仓和再平衡机制、交易成本、强基线、滚动样本外回测以及跨市场验证。

Q16：如果继续做，最优先改什么？

第一，核验数据来源和复权口径；第二，扩大股票池并处理成分变化；第三，比较不同窗口参数；第四，加入持久性、AR/GARCH 等强基线；第五，做“仅波动率、仅结构、二者结合”的消融实验；第六，开展 walk-forward 和跨市场验证。

Q17：这项工作与量化研究有什么关系？

它属于量化市场结构分析与风险状态识别。数据清洗、特征构建、滚动建模、无监督学习、样本外预测和结果解释都属于量化研究流程，只是还没有扩展到完整交易策略。

Q18：为什么项目叫 MarketManifold？

因为我们更倾向于把股票理解为位于连续的动态风险结构中，而不是几个长期固定、边界清晰的类别。MDS 图和较低轮廓系数都与“连续结构”这一理解相符。

5 现场表达禁区

不要说

建议改说

“我们证明了波动率导致相关性上升。”

“样本中二者高度同步，但尚未建立因果关系。”



不要说	建议改说
“最新美股很安全。”	“最新窗口的共同运动较弱，横截面更分散。”
“聚类发现了六个真实行业。”	“聚类提供了六组数据驱动的近似划分。”
“模型能预测市场。”	“特征组合在当前样本中表现出探索性的短期统计信息。”
“117 个独立样本。”	“117 个高度重叠的滚动窗口。”
“MDS 的横轴就是某个经济因子。”	“MDS 轴本身不具固定经济含义，重点是相对距离。”
“相关系数 0.993 说明模型特别强。”	“两个指标本来都刻画共同因子强度，因此高度一致。”



6 一页速查卡

项目主线

价格 → 对数收益率 → 90 日相关矩阵 → 相关距离 → MDS → 聚类 → Procrustes 对齐 → 结构指标与探索性预测。

必须记住的数字

样本	46 只股票, 11 个行业, 约 2021.06–2026.06
共同交易日	1255
正式窗口	90 日窗口, 10 日步长, 117 个窗口
GIF	90 日窗口, 1 日步长, 仅用于连续展示
三组相关系数	0.959, 0.993, 0.978
最高波动窗口	2022-08-30, 波动率 0.261, 相关性 0.510
最高相关窗口	2022-12-22, 相关性 0.543, PC1 解释率 0.564
最新窗口	2026-06-15, 相关性 0.105, 波动率 0.116, PC1 解释率 0.213
最新二维平均距离	1.159
相邻窗口 ARI	0.741
行业-聚类 ARI / NMI	0.163 / 0.461
平均轮廓系数	0.109
最佳探索性预测	线性回归: MAE 0.0185, RMSE 0.0289, $R^2 = 0.640$

每页一句话

1. 我们研究的是股票之间的动态关系, 而不是单只股票价格。
2. 高压时结构集中, 稳定时结构分散。
3. 46 只股票、1255 日、90 日窗口、117 个正式窗口。
4. 价格数据被转换成动态市场地图。
5. 相关性变成距离, MDS 画图, Procrustes 保持方向稳定。
6. GIF 看点云收缩、分散和群组重组。
7. 波动率、平均相关性和 PC1 高度同步。
8. 最新窗口比 2022 年压力阶段明显分散。
9. 聚类连续, 但不是行业分类的复制, 且边界有限。
10. 预测只是探索性统计验证, 不是交易策略。
11. 风险不仅表现为波动, 也表现为关联结构同步收缩。

最危险的三个问题

1. **窗口重叠:** 承认有效独立样本更少, 因此结果偏探索性。
2. **轮廓系数低:** 解释为连续风险空间, 不强行宣称天然类别。



3. **预测基线弱：**承认下一步需要持久性基线和消融实验。

开场与结尾

大家好，我是陶圣叶。今天汇报的项目是 MarketManifold。我们不直接预测某只股票，而是把市场看成一个随时间变化的关系网络，研究股票之间的联动结构如何在高波动和稳定阶段之间切换。

本项目的核心认识是：市场风险不仅表现为价格波动，也表现为资产关联结构的同步收缩。当前结果主要用于市场状态观察和风险理解，不构成因果结论或交易策略。谢谢大家。

7 排练、时间控制与故障预案

7.1 上台前 30 分钟检查

- PPT 能否正常打开，字体是否替换；
- GIF 是否嵌入文件而不是外部链接；
- 放映模式下 GIF 能否自动播放和循环；
- 同目录保留 GIF、MP4、PDF 和静态 PNG 备份；
- 关闭拼写检查红色波浪线；
- 电脑电源、转接头、翻页器和音量；
- 报告 PDF、源码 ZIP 和 PPT 各有一份本地备份与云端备份。

7.2 两轮排练法

1. **第一轮：理解排练。**允许停顿，重点确认每页为什么存在、与前后页如何衔接。
2. **第二轮：计时排练。**完整讲一遍，不暂停修改。结束后只修超时最多的两页。
不要追求逐字一致。只要每页都能稳定说出“本页问题、证据、结论、边界”四项即可。

7.3 超时处理

如果时间不足，按以下顺序压缩：

1. 第 4 页十步流程不逐条读，只讲“相关矩阵-距离-MDS-聚类-对齐”；
2. 第 5 页只解释相关距离和 MDS，Procrustes 用一句话；
3. 第 8 页只讲 2022 压力窗口与最新窗口；
4. 第 10 页只讲线性回归最好和三项局限；
5. 第 11 页保留核心 takeaway，绝不删结尾。

7.4 GIF 故障

这段动画展示的是 90 日窗口按交易日连续推进的结果。如果现场动画无法播放，当前静态帧仍然说明每个点代表一只股票、颜色表示聚类、距离表示收益联动。后面的三个代表性窗口会进一步展示集中与分散的差异。

说完立即翻到下一页，不要现场修文件。

7.5 突然忘词

使用四句恢复模板：

1. “这一页我们主要回答的是……”
2. “左侧图表给出的直接证据是……”



3. “因此可以得到的结论是……”
4. “但需要注意的边界是……”

7.6 老师提出无法立即回答的问题

这个问题很关键。当前实验还没有单独完成这一项验证，所以我不想根据现有结果直接下结论。按照您的问题，下一步可以通过（更换窗口参数 / 加入持久性基线 / 扩大股票池 / 做消融实验 / 跨市场验证）来检验。

承认边界比临场编造更专业。

8 展示前最后判断

你真正需要掌握的四句话

1. 我们研究的是股票之间的动态关系结构。
2. 高波动时，共同运动增强，市场结构集中。
3. 动态聚类有连续性，但不等同于行业，也不是边界清晰的天然类别。
4. 预测结果是探索性统计证据，不是交易策略。

能够围绕这四句话展开，整场展示就不会失控。